

SAFE-Alert: Hệ thống dự báo và cảnh báo tài chính thời gian thực dựa trên chọn lọc tin tức, giải thích theo yếu tố và đánh giá độ tin cậy

Abstract

Các hệ thống dự báo tài chính dựa trên tin tức hiện nay thường gặp ba hạn chế cốt lõi: (i) xử lý dư thừa thông tin khi xem mọi bài báo là quan trọng như nhau, (ii) cung cấp giải thích hậu nghiệm còn nông, thường dừng ở mức điểm cảm xúc hoặc câu diễn giải chung chung, và (iii) phát tín hiệu dự báo mà không kiểm soát đầy đủ độ tin cậy, dẫn đến cảnh báo nhiều và hiệu quả đầu tư suy giảm trong môi trường thời gian thực. Những hạn chế này đặc biệt nghiêm trọng trong thị trường tiền mã hóa, nơi tin tức dày đặc, phản ứng giá nhanh, và chi phí của tín hiệu sai là rất lớn.

Bài báo này đề xuất một khung dự báo và hỗ trợ quyết định thời gian thực mới, có tên là **SAFE-Alert** (*Selective Attentive Factor-Explainable Alerting*), nhằm chuyển bài toán từ *news-to-prediction* sang *news-to-signal* với khả năng giải thích và kiểm soát độ tin cậy. Cụ thể, phương pháp đề xuất tích hợp bốn thành phần trong một kiến trúc thống nhất: (1) cơ chế **chọn lọc tin tức thích nghi** để xác định tập bài viết quan trọng nhất theo từng tài sản và từng khung thời gian; (2) mô hình **hợp nhất đa phương thức** giữa tin tức đã chọn và ngữ cảnh thị trường đa khung thời gian để dự báo hướng giá, biên độ thay đổi và mức độ biến động; (3) tầng **giải thích dựa trên yếu tố** (*factor-grounded explanation*) giúp liên kết dự báo với các tác nhân tài chính có ý nghĩa thay vì chỉ cung cấp diễn giải ngôn ngữ chung chung; và (4) cơ chế **cảnh báo nhận thức độ tin cậy** (*confidence-aware alerting*) cho phép hệ thống chỉ phát tín hiệu khi mức chắc chắn vượt qua ngưỡng hiệu chỉnh.

Điểm mới cốt lõi của nghiên cứu không nằm ở từng mô-đun riêng lẻ, mà ở việc thống nhất **lựa chọn bằng chứng, dự báo, giải thích và kiểm soát cảnh báo** trong cùng một vòng lặp suy luận gần thời gian thực. Khung đề xuất được thiết kế để triển khai trực tiếp trên một nền tảng microservices hướng sự kiện, nơi dữ liệu tin tức, dữ liệu giá và kết quả dự báo được đồng bộ qua Kafka, lưu trữ trong các kho dữ liệu chuyên biệt, và đánh giá đầu-cuối thông qua cả chỉ số học máy lẫn chỉ số tài chính. Trên phương diện thực nghiệm, bài báo hướng đến chứng minh rằng

việc chỉ sử dụng một tập tin tức chọn lọc, kèm giải thích theo yếu tố và chiến lược từ chối phát cảnh báo khi bất định cao, có thể đồng thời cải thiện chất lượng dự báo, độ trung thực của giải thích và hiệu quả giao dịch so với các mô hình sử dụng toàn bộ tin tức hoặc chỉ sinh giải thích hậu nghiệm.

Nhờ kết hợp chặt chẽ giữa dự báo đa phương thức, giải thích có cấu trúc và cơ chế cảnh báo có trách nhiệm, nghiên cứu này hướng tới một lớp hệ thống hỗ trợ quyết định tài chính thông minh mới: không chỉ *dự báo điều gì sẽ xảy ra*, mà còn *chỉ ra vì sao tin hiệu đó đáng tin* và *khi nào hệ thống nên im lặng*. Đây là bước tiến quan trọng để thu hẹp khoảng cách giữa các mô hình dự báo học sâu và yêu cầu triển khai thực tế trong các nền tảng phân tích tài chính vận hành thời gian thực.

Keywords: financial forecasting, explainable AI, large language models, selective news selection, multimodal learning, confidence-aware alerting, cryptocurrency market

1. Giới thiệu

Dự báo tài chính dựa trên tin tức đang trở thành một hướng nghiên cứu trọng tâm trong giao điểm giữa học máy, xử lý ngôn ngữ tự nhiên và hệ hỗ trợ quyết định. Trong các thị trường biến động cao như tiền mã hóa, dữ liệu giá lịch sử tuy phản ánh hành vi thị trường trong quá khứ nhưng thường không đủ để mô tả đầy đủ các cú sốc thông tin mới xuất hiện, trong khi tin tức và văn bản tài chính lại cung cấp ngữ cảnh định tính có khả năng làm thay đổi kỳ vọng thị trường gần như tức thời. Chính vì vậy, việc kết hợp dữ liệu giá với dữ liệu tin tức đã trở thành một hướng tiếp cận tự nhiên cho các hệ thống dự báo tài chính hiện đại [1, 2, 3].

Mặc dù vậy, phần lớn các hệ thống hiện nay vẫn gặp ba hạn chế căn bản. Thứ nhất, nhiều phương pháp giảm toàn bộ thông tin văn bản về các tín hiệu cảm xúc phẳng như *positive*, *negative* hoặc *neutral*. Cách làm này hữu ích cho việc tóm lược xu hướng ngôn ngữ, nhưng thường bỏ qua cơ chế tác động thực sự của một bài viết lên giá tài sản và không phân biệt được giữa *tin tích cực về mặt câu chữ* với *tin có tác động thực sự lên thị trường* [1, 2]. Thứ hai, không phải mọi tin tức trong một cửa sổ thời gian đều quan trọng như nhau; tuy nhiên, nhiều mô hình vẫn hoặc cộng gộp toàn bộ tin, hoặc lọc tin bằng các tiêu chí thủ công cố định, dẫn đến tình trạng *information overload* hoặc bỏ sót các sự kiện thực sự dịch chuyển thị trường [4]. Thứ ba, ngay cả khi mô hình tạo ra dự báo hợp lý, phần giải thích thường vẫn còn nông, chủ yếu dừng ở attention heatmap, sentiment score hoặc diễn giải hậu nghiệm không gắn chặt với cơ chế ra quyết định của mô hình [5].

Những hạn chế này đặc biệt nghiêm trọng trong các hệ thống vận hành gần thời gian thực. Trong bối cảnh đó, bài toán không còn đơn thuần là *dự báo điều gì sẽ xảy ra*, mà phải mở rộng thành ba câu hỏi đồng thời: *bằng chứng nào thực sự quan trọng*, *yếu tố nào đang chi phối tín hiệu*, và *khi nào hệ thống đủ tự tin để phát cảnh báo*. Nếu không giải quyết được ba câu hỏi này, một hệ thống dự báo dù có độ chính xác hợp lý vẫn khó được tin cậy trong thực tế triển khai, đặc biệt khi đầu ra của nó được sử dụng để hỗ trợ quyết định đầu tư hoặc kích hoạt cảnh báo tự động [5].

Các nghiên cứu gần đây đã bắt đầu chú ý tới từng phần của bài toán trên. Ở tầng *evidence selection*, Jang [4] đề xuất *News Selection Model* nhằm thích nghi chọn ra một tập headline quan trọng nhất từ dòng tin hàng ngày, sau đó kết hợp tập tin đã chọn với dữ liệu giá qua cơ chế cross-attention. Kết quả thực nghiệm cho thấy việc chọn lọc bằng chứng có thể cải thiện cả hiệu năng dự báo lẫn khả năng giải thích so với cách dùng toàn bộ tin đầu vào [4]. Tuy nhiên, hướng này chủ yếu trả lời câu hỏi *nên chọn bài báo nào*, trong khi vẫn đề ngỏ câu hỏi *nên diễn giải tín hiệu bằng cấu trúc tri thức nào* và *khi nào mô hình nên giữ im lặng thay vì luôn phát tín hiệu*.

Ở tầng *explanation*, các mô hình ngôn ngữ lớn đã tạo ra một dịch chuyển đáng kể từ sentiment-based forecasting sang reasoning-aware forecasting. Thay vì chỉ gán nhãn cảm xúc cho văn bản, *LLMFactor* cho thấy LLM có thể được điều khiển để trích xuất các *yếu tố (factors)* tác động đến biến động giá, từ đó tạo ra lời giải thích gần với logic tài chính hơn so với sentiment hoặc keyphrases đơn thuần [6]. Theo một hướng khác, *Summarize-Explain-Predict* chứng minh rằng LLM có thể được huấn luyện để vừa dự báo vừa sinh giải thích bằng lời thông qua cơ chế tự phân tư, thay vì chỉ cung cấp diễn giải hậu nghiệm sau dự báo [7]. Tuy nhiên, các nghiên cứu này chủ yếu nhấn mạnh khả năng sinh lời giải thích hoặc trích xuất yếu tố, chứ chưa giải quyết đầy đủ bài toán chọn lọc bằng chứng và kiểm soát tín hiệu trong môi trường triển khai thời gian thực.

Song song với đó, nhánh dự báo đa phương thức cũng đang phát triển nhanh. *FININ* chỉ ra rằng quá trình khuếch tán thông tin tài chính vào giá thị trường là một quá trình phức tạp, trong đó ảnh hưởng của một tin không chỉ phụ thuộc vào bản thân bài báo đó mà còn phụ thuộc vào tương tác giữa các bài báo, độ trễ hấp thụ thông tin và hiệu ứng ghi nhớ dài hạn của dòng tin [2]. Gần đây hơn, Koval và cộng sự [3] đề xuất mô hình đa phương thức cho chuỗi văn bản–thời gian xen kẽ, cho thấy việc học căn chỉnh liên mô thức có thể cải thiện cả chất lượng dự báo lẫn utility kinh tế trong mô phỏng đầu tư. Dù vậy, các công trình này vẫn chủ yếu tập trung vào *forecasting accuracy* hoặc *multimodal fusion*, trong khi phần *explainable alerting* vẫn chưa được phát triển thành một cơ chế thống nhất.

Một khoảng trống quan trọng khác nằm ở *độ tin cậy vận hành*. Trong thực tế, một hệ thống hỗ trợ quyết định tài chính không chỉ cần dự báo chính xác hơn, mà còn cần biết *khi nào không nên phát cảnh báo*. Trong literature dự báo chuỗi thời gian tổng quát, *selective forecasting* đã cho thấy rằng việc từ chối các dự báo có mức bất định cao có thể làm giảm lỗi và tăng mức độ an toàn khi triển khai [8]. Tuy nhiên, trong tài chính, đặc biệt là trong các hệ thống cảnh báo dựa trên tin tức, ý tưởng này vẫn chưa được tích hợp chặt chẽ với lựa chọn bằng chứng, giải thích theo yếu tố và utility downstream. Đây chính là khoảng trống khiến nhiều hệ thống hiện nay hoặc quá nhạy và phát nhiều tín hiệu nhiễu, hoặc quá bảo thủ và làm giảm đáng kể giá trị sử dụng của nền tảng.

Từ các khoảng trống trên, bài báo này xuất phát từ một lập trường rõ ràng: một hệ thống dự báo tài chính thời gian thực không nên được đánh giá chỉ bằng việc nó dự báo điều gì sẽ xảy ra, mà còn phải được đánh giá bằng khả năng chỉ ra *bằng chứng nào là quan trọng, yếu tố nào đang chi phối tín hiệu, và khi nào tín hiệu đó đủ đáng tin để hành động*. Trên cơ sở đó, chúng tôi đề xuất **SAFE-Alert** (*Selective Attentive Factor-Explainable Alerting*), một khung thống nhất cho dự báo tín hiệu tài chính từ tin tức trong môi trường gần thời gian thực. Khung đề xuất kết hợp bốn thành phần: (i) chọn lọc tin tức thích nghi theo từng tài sản và từng chân trời dự báo, (ii) hợp nhất đa phương thức giữa bằng chứng đã chọn và ngữ cảnh thị trường đa khung thời gian, (iii) giải thích dựa trên yếu tố nhằm liên kết dự báo với các cơ chế tài chính có nghĩa, và (iv) cơ chế cảnh báo nhận thức độ tin cậy cho phép hệ thống chỉ phát tín hiệu khi mức chắc chắn vượt qua ngưỡng đã hiệu chỉnh.

Điểm mới cốt lõi của nghiên cứu không nằm ở một mô-đun đơn lẻ, mà ở việc thống nhất *selection, forecasting, explanation* và *alerting* trong cùng một vòng lặp suy luận. Khác với các phương pháp chỉ thêm một tầng diễn giải sau dự báo, SAFE-Alert xem việc lựa chọn bằng chứng, trích xuất yếu tố, ước lượng độ tin cậy và quyết định phát cảnh báo là các thành phần đồng thiết kế. Cách nhìn này giúp chuyển bài toán từ *news-to-prediction* sang *news-to-signal*, phù hợp hơn với yêu cầu của các hệ thống hỗ trợ quyết định trong tài chính thời gian thực.

Các đóng góp chính của bài báo được tóm tắt như sau:

- Chúng tôi đề xuất một khung dự báo tín hiệu tài chính mới tích hợp đồng thời *selective news selection, factor-grounded explanation* và *confidence-aware alerting* trong một kiến trúc thống nhất.
- Chúng tôi thiết kế một cơ chế hợp nhất đa phương thức giữa tin tức đã chọn và dữ liệu thị trường đa khung thời gian nhằm hỗ trợ dự báo theo nhiều chân trời thời gian và sinh giải thích có cấu trúc.

- Chúng tôi đưa selective forecasting vào bài toán cảnh báo tài chính dựa trên tin tức, từ đó đánh giá hệ thống không chỉ bằng các chỉ số dự báo chuẩn mà còn bằng độ tin cậy, chất lượng cảnh báo và utility trong backtest.
- Chúng tôi định vị phương pháp đề xuất như một lớp hệ thống hỗ trợ quyết định gần thời gian thực, qua đó thu hẹp khoảng cách giữa các mô hình dự báo học sâu và yêu cầu triển khai thực tế trong các nền tảng phân tích tài chính hiện đại.

Phần còn lại của bài báo được tổ chức như sau. Mục 2 trình bày các hướng nghiên cứu liên quan về phân tích cảm xúc tài chính, chọn lọc tin tức, dự báo đa phương thức, giải thích bằng LLM và selective forecasting. Mục 3 phát biểu bài toán và mô tả chi tiết khung SAFE-Alert. Mục 4 trình bày dữ liệu, giao thức thực nghiệm, các baseline và tiêu chí đánh giá. Mục 5 báo cáo kết quả định lượng và phân tích định tính. Cuối cùng, Mục ?? kết luận bài báo và thảo luận các hướng phát triển tiếp theo.

2. Công trình liên quan

Phần này tổng hợp các hướng nghiên cứu gần nhất có liên quan trực tiếp đến bài toán của chúng tôi, bao gồm: (i) phân tích cảm xúc tài chính và các giới hạn của biểu diễn sentiment phẳng, (ii) lựa chọn tin tức thích nghi cho dự báo tài chính, (iii) giải thích dựa trên LLM và yếu tố tài chính, (iv) dự báo đa phương thức từ văn bản và chuỗi thời gian, và (v) selective forecasting cùng hiệu chỉnh độ tin cậy cho cảnh báo. Mặc dù từng nhánh đã đạt được tiến bộ đáng kể, chúng tôi chỉ ra rằng vẫn còn thiếu một khung thống nhất kết nối *lựa chọn bằng chứng, dự báo, giải thích theo yếu tố và kiểm soát phát cảnh báo* trong môi trường tài chính gần thời gian thực.

2.1. Phân tích cảm xúc tài chính và các giới hạn của biểu diễn sentiment phẳng

Financial Sentiment Analysis (FSA) là một hướng nghiên cứu đã phát triển mạnh trong nhiều năm qua, với các ứng dụng từ phân tích tin tức, báo cáo tài chính, earnings calls cho đến đánh giá rủi ro thị trường [1]. Tuy nhiên, survey gần đây của Du và cộng sự [1] cho thấy một vấn đề lặp lại trong phần lớn hệ thống FSA là việc quy giản văn bản tài chính thành một tín hiệu cảm xúc phẳng ở mức câu, đoạn hoặc tài liệu, chẳng hạn như *positive*, *negative* hoặc *neutral*. Dù cách biểu diễn này thuận tiện cho việc huấn luyện và đánh giá, nó thường không đủ để phản ánh đầy đủ động lực tài chính thực sự, nơi cùng một cụm từ có thể mang tác

động thị trường rất khác nhau tùy vào bối cảnh vĩ mô, loại tài sản, thời điểm công bố và trạng thái thị trường hiện tại [1, 5].

Một vấn đề gần đây được nhấn mạnh là sentiment ở mức tài liệu thường không đủ tinh để phản ánh tác động lên từng đối tượng trong tin tài chính. Muhammad và cộng sự [9] cho thấy *target-based financial sentiment analysis* là một bài toán quan trọng nhưng còn chưa được nghiên cứu đầy đủ, đặc biệt khi một bài viết có thể đồng thời đề cập đến nhiều thực thể với sắc thái khác nhau. Kết quả của họ cũng cho thấy các LLM tạo sinh mạnh như ChatGPT hay DeepSeek-R1 có tiềm năng cao trong phân tích sentiment ở mức target mà không cần fine-tuning sâu [9]. Bên cạnh đó, Kumar và Nalbaria [10] chỉ ra thêm một hạn chế thực tế của FSA là *sự lỗi thời của dữ liệu gán nhãn*: nhiều benchmark chuẩn không còn phản ánh tốt ngôn ngữ tài chính đương đại, khiến các mô hình học từ dữ liệu cũ dễ suy giảm hiệu năng khi triển khai trên tin tức mới.

Từ góc nhìn bài toán của chúng tôi, các kết quả trên cho thấy hai điểm quan trọng. Thứ nhất, sentiment tài chính không nên được xem là một scalar tĩnh, mà cần được đặt trong ngữ cảnh bằng chứng, thực thể và thời gian. Thứ hai, nếu bài toán đích là phát tín hiệu giao dịch hoặc cảnh báo, thì sentiment cần được gắn chặt hơn với *tác động dự báo* và *ngữ cảnh thị trường*, thay vì tồn tại như một đầu ra NLP độc lập.

2.2. Lựa chọn tin tức thích nghi cho dự báo thị trường

Một trong những pain point lớn nhất của các hệ thống dự báo dựa trên tin tức là *information overload*. Trong môi trường tài chính thời gian thực, số lượng bài viết xuất hiện trong một cửa sổ ngắn có thể rất lớn, nhưng chỉ một phần nhỏ trong đó thực sự liên quan đến chuyển động giá của tài sản mục tiêu. Các mô hình cộng gộp toàn bộ tin thường làm loãng tín hiệu, trong khi các heuristic thủ công như lọc theo nguồn, recency hay sentiment magnitude lại dễ bỏ sót các bài báo có ý nghĩa thị trường [4].

Để giải quyết vấn đề này, Jang [4] đề xuất một *Selective News Selection Model* sử dụng cơ chế lựa chọn thích nghi dựa trên differentiable Top- K và cross-attention integration giữa tập bài viết đã chọn với đặc trưng giá. Kết quả của nghiên cứu này cho thấy việc chọn lọc tin tức không chỉ tăng accuracy mà còn cải thiện khả năng giải thích bằng cách chỉ ra rõ những headline thực sự đóng góp vào dự báo [4]. Đây là một bước tiến quan trọng vì nó dịch chuyển bài toán từ *all-news modeling* sang *evidence-aware forecasting*. Tuy nhiên, nghiên cứu trên chủ yếu dừng ở mức lựa chọn headline quan trọng và tích hợp với giá; nó chưa trả lời đầy đủ các câu hỏi về *giải thích ở mức yếu tố tài chính* và *khi nào hệ thống nên giữ im lặng* thay vì luôn phát tín hiệu.

Điều này khiến nhánh selective news selection trở thành một nền tảng rất phù hợp cho bài toán của chúng tôi. Chúng tôi kế thừa tinh thần *evidence selection* này, nhưng mở rộng nó sang một khung rộng hơn, nơi selection không phải là đích cuối cùng mà là điều kiện đầu vào cho hai thành phần tiếp theo: *factor-grounded explanation* và *confidence-aware alerting*.

2.3. Giải thích dựa trên LLM và yếu tố tài chính

Sự nổi lên của các mô hình ngôn ngữ lớn đã thúc đẩy một chuyển dịch đáng kể từ *sentiment-based explanation* sang *reasoning-based explanation*. Trong bối cảnh dự báo tài chính, thay vì chỉ gắn nhãn cảm xúc hoặc trích xuất keyphrases, các nghiên cứu mới bắt đầu yêu cầu mô hình phải chỉ ra *yếu tố nào* đang thúc đẩy tín hiệu và *vì sao* yếu tố đó có liên hệ với biến động giá.

Một công trình tiêu biểu là *LLMFactor* của Wang và cộng sự [6], trong đó tác giả sử dụng *Sequential Knowledge-Guided Prompting* để buộc LLM trích xuất các yếu tố có khả năng sinh lợi từ tin tức, sau đó dùng các yếu tố này để giải thích và hỗ trợ dự báo stock movement. Kết quả cho thấy factor-based prompting hiệu quả hơn việc chỉ dùng sentiment hoặc keyphrases trong một số benchmark dự báo cổ phiếu [6]. Theo một hướng khác, Koa và cộng sự [7] đề xuất mô hình *Summarize-Explain-Predict*, trong đó LLM vừa sinh tóm tắt, vừa sinh giải thích, vừa dự báo thông qua cơ chế tự phản tư, cho thấy giải thích có thể được học như một phần của pipeline dự báo chứ không chỉ là hậu xử lý.

Ở bài toán FSA thuần túy, Pallucchini và cộng sự [11] đề xuất một framework *self-explanatory and retrieval-augmented* nhằm làm giàu câu tài chính bằng tri thức bổ sung trước khi phân tích sentiment. Điểm đáng chú ý của công trình này là nó không chỉ dùng LLM để sinh lại văn bản mà còn đưa ra một cơ chế chọn lựa các câu tăng cường phù hợp, qua đó vừa cải thiện độ diễn giải vừa hỗ trợ bài toán hạ nguồn [11]. Song song với đó, survey của Yeo và cộng sự [5] chỉ ra rằng XAI trong tài chính đang dịch chuyển từ các kỹ thuật feature attribution cổ điển sang các chiến lược giải thích có cấu trúc hơn, nhưng vẫn còn thiếu các cơ chế đảm bảo *faithfulness* và *operational trustworthiness* khi áp dụng vào hệ thống ra quyết định.

Nhìn chung, các nghiên cứu trên đã chứng minh rằng LLM và XAI có thể giúp tăng khả năng diễn giải trong tài chính. Tuy nhiên, phần lớn chúng vẫn tập trung vào một trong hai cực: hoặc tăng chất lượng giải thích ngôn ngữ, hoặc tăng hiệu quả sentiment/prediction, trong khi chưa tích hợp chặt giữa *selected evidence*, *factor semantics*, *forecast output* và *decision policy*. Đây là khoảng trống quan trọng mà bài báo của chúng tôi nhắm tới.

2.4. Dự báo đa phương thức từ văn bản và chuỗi thời gian

Bên cạnh nhánh FSA thuần túy, một hướng phát triển mạnh trong hai năm gần đây là mô hình hóa đồng thời văn bản tài chính và chuỗi thời gian thị trường. Động lực của hướng này là giá không phản ứng với văn bản theo cách tuyến tính hoặc tức thì; thay vào đó, tác động của tin tức phụ thuộc vào *state* của thị trường, độ trễ hấp thụ thông tin, cũng như tương tác giữa các bài báo trong cùng một cửa sổ thời gian.

Wang và cộng sự [2] đề xuất *Financial Interconnected News Influence Network* (FININ), nhấn mạnh rằng ảnh hưởng của tin tức không nên được xem xét độc lập mà cần được mô hình hóa cùng với tương tác giữa các bài báo và ngữ cảnh thị trường. Gần đây hơn, Koval và cộng sự [3] đưa ra một kiến trúc đa phương thức cho chuỗi văn bản–thời gian xen kẽ, trong đó các experts theo modality và cơ chế cross-modal alignment được dùng để gắn văn bản với price trajectories. Công trình này báo cáo cả cải thiện về hiệu năng dự báo lẫn utility kinh tế trong mô phỏng đầu tư [3]. Các kết quả đó cho thấy việc kết hợp văn bản và chuỗi thời gian là cần thiết nếu mục tiêu là dự báo trong môi trường tài chính thực.

Tuy nhiên, ngay cả trong các mô hình đa phương thức mạnh nhất hiện nay, phần *explainable decision support* vẫn chưa được phát triển đầy đủ. Phần lớn các mô hình ưu tiên *forecasting accuracy* hoặc *economic gain* nhưng chưa trả lời rõ ba câu hỏi thiết kế quan trọng đối với hệ thống triển khai: *tin nào thực sự đáng giữ lại*, *yếu tố nào đang chi phối dự báo*, và *khi nào không nên gửi tín hiệu*. Bài toán của chúng tôi kế thừa nhánh đa phương thức này, nhưng thay vì chỉ tối ưu dự báo, chúng tôi xây dựng toàn bộ pipeline quanh *signal trustworthiness*.

2.5. Selective forecasting, hiệu chỉnh độ tin cậy và chính sách cảnh báo

Trong nhiều ứng dụng rủi ro cao, một mô hình tốt không chỉ là mô hình dự báo chính xác mà còn là mô hình biết *khi nào không nên dự báo*. Ý tưởng này được nghiên cứu rộng trong selective prediction và selective forecasting. Ở lĩnh vực chuỗi thời gian, Brusokas và cộng sự [8] đề xuất *Time-Energy Model*, trong đó mô hình học một hàm năng lượng để ước lượng chất lượng dự báo, từ đó chọn ra những dự báo đáng tin và từ chối các trường hợp có rủi ro cao. Kết quả cho thấy selective forecasting có thể giảm lỗi dự báo đáng kể so với chế độ luôn dự báo [8].

Tuy nhiên, các ý tưởng selective forecasting hiện chủ yếu được phát triển trong bối cảnh time-series tổng quát. Trong tài chính, đặc biệt là với các hệ thống *news-driven alerting*, vẫn còn thiếu những nghiên cứu tích hợp chặt giữa *evidence selection*, *forecast confidence*, *explanation faithfulness* và *alert policy*. Nói cách khác, literature hiện tại đã bắt đầu trả lời câu hỏi *dự báo nào nên giữ lại*, nhưng

chưa trả lời đầy đủ câu hỏi *tín hiệu nào nên phát cho người dùng cuối* trong một nền tảng hỗ trợ quyết định thời gian thực.

Khoảng trống này đặc biệt đáng chú ý trong các hệ thống tài chính thực tế, nơi chi phí của một cảnh báo sai không chỉ là mất điểm accuracy, mà còn có thể chuyển thành giao dịch sai, nhiễu thông tin và suy giảm lòng tin của người dùng vào hệ thống. Vì vậy, việc đưa *confidence-aware alerting* vào một khung dự báo từ tin tức không chỉ là một tinh chỉnh kỹ thuật, mà là một thành phần trung tâm của thiết kế hệ thống hỗ trợ quyết định.

2.6. Tóm tắt khoảng trống nghiên cứu

Tổng hợp các hướng nghiên cứu trên cho thấy literature hiện tại đã có những bước tiến mạnh ở từng mảnh của bài toán:

- FSA và target-based FSA giúp làm rõ sắc thái và thực thể trong văn bản tài chính [1, 9];
- selective news selection giúp giảm information overload và làm rõ bằng chứng đầu vào [4];
- LLM-based factor extraction và self-explanatory forecasting cải thiện khả năng diễn giải của mô hình [6, 7, 11];
- multimodal forecasting giúp học tốt hơn mối liên hệ giữa tin tức và ngữ cảnh thị trường [2, 3];
- selective forecasting mở đường cho việc từ chối các dự báo bất định cao [8].

Tuy nhiên, theo hiểu biết tốt nhất của chúng tôi, vẫn còn thiếu một khung thống nhất cho tài chính gần thời gian thực có khả năng:

1. chọn ra *một tập bằng chứng tin tức thực sự quan trọng*,
2. ánh xạ bằng chứng đó sang *các yếu tố tài chính có nghĩa*,
3. kết hợp chúng với *ngữ cảnh thị trường đa khung thời gian*,
4. và chỉ phát *cảnh báo có giải thích* khi mô hình đủ tự tin.

Chính khoảng trống này tạo nên động lực cho SAFE-Alert. Khác với các hướng trước, phương pháp của chúng tôi không xem selection, prediction, explanation và alerting là các bước tách rời, mà xem chúng là các thành phần đồng thiết kế của một hệ thống hỗ trợ quyết định tài chính thời gian thực.

3. Phát biểu bài toán và phương pháp đề xuất

3.1. Phát biểu bài toán

Xét một tập tài sản giao dịch $\mathcal{S}$, một tập chân trời dự báo $\mathcal{H} = \{15m, 1h, 4h, 24h\}$, và một dãy thời điểm quyết định $t \in \mathcal{T}$. Với mỗi tài sản $s \in \mathcal{S}$ tại thời điểm t , hệ thống quan sát đồng thời hai nguồn thông tin: (i) luồng tin tức liên quan đến tài sản đó trong một cửa sổ thời gian gần đây, và (ii) trạng thái thị trường đa khung thời gian ngay trước thời điểm ra quyết định.

Cụ thể, ta ký hiệu:

- $\mathcal{N}_{s,t} = \{n_i\}_{i=1}^{N_{s,t}}$ là tập các bài viết liên quan đến tài sản s xuất hiện trong cửa sổ tin tức $[t - W_n, t]$, với $N_{s,t}$ là số lượng bài viết;
- mỗi bài viết n_i bao gồm nội dung văn bản x_i , thời điểm công bố τ_i , nguồn tin u_i , và metadata m_i (ví dụ: độ mới, độ dài, độ tin cậy nguồn, độ mới lạ của nội dung);
- $\mathcal{M}_{s,t} = \{\mathbf{X}_{s,t}^{(\delta)}\}_{\delta \in \Delta}$ là tập tensor đặc trưng thị trường đa khung thời gian, với $\Delta = \{1m, 5m, 15m, 1h, 4h\}$, trong đó $\mathbf{X}_{s,t}^{(\delta)} \in \mathbb{R}^{L_\delta \times d_\delta}$ là chuỗi đặc trưng của L_δ nền gần nhất ở khung δ .


Mục tiêu của bài toán là học một ánh xạ

$$f_\theta : (\mathcal{N}_{s,t}, \mathcal{M}_{s,t}, h) \mapsto \left(\hat{y}_{s,t}^{(h)}, \hat{r}_{s,t}^{(h)}, \hat{c}_{s,t}^{(h)}, \hat{\mathcal{E}}_{s,t}^{(h)} \right), \quad (1)$$

trong đó:

- $\hat{y}_{s,t}^{(h)} \in \{-1, 0, +1\}$ là nhãn hướng giá dự báo cho chân trời h (giảm, trung tính, tăng);
- $\hat{r}_{s,t}^{(h)} \in \mathbb{R}$ là suất sinh lợi kỳ vọng hoặc biên độ biến động kỳ vọng;
- $\hat{c}_{s,t}^{(h)} \in [0, 1]$ là mức độ tin cậy của tín hiệu;
- $\hat{\mathcal{E}}_{s,t}^{(h)}$ là tập giải thích có cấu trúc, bao gồm các bài viết được chọn, các yếu tố tài chính (*factors*) và một diễn giải ngắn gọn ở mức người dùng.

Không giống các bài toán dự báo chuẩn chỉ tối ưu $\hat{y}_{s,t}^{(h)}$ hoặc $\hat{r}_{s,t}^{(h)}$, bài toán của chúng tôi là bài toán *news-to-signal*: hệ thống không chỉ dự báo chuyển động giá, mà còn phải xác định *bằng chứng nào nên được giữ lại, yếu tố nào đang chi phối tín hiệu*, và *khi nào nên phát cảnh báo*. Điều này dẫn đến ba ràng buộc thiết kế đồng thời:



Hình 1: Tổng quan kiến trúc SAFE-Alert. Hệ thống bắt đầu từ luồng tin tức và ngữ cảnh thị trường đa khung thời gian, sau đó lần lượt đi qua bốn tầng: (1) chọn lọc tin tức thích nghi, (2) suy luận dựa trên yếu tố tài chính, (3) hợp nhất đa phương thức với ngữ cảnh thị trường, và (4) dự báo, giải thích và cảnh báo nhận thức độ tin cậy. Kiến trúc này được tích hợp trực tiếp với vòng lặp hệ thống gồm crawler, AI service, core storage, notification và backtest để hỗ trợ suy luận gần thời gian thực và đánh giá utility downstream.

1. **Tính chọn lọc:** chỉ một phần nhỏ của $\mathcal{N}_{s,t}$ là thực sự hữu ích cho dự báo;
2. **Tính diễn giải:** dự báo phải được gắn với các yếu tố tài chính có nghĩa thay vì chỉ với điểm cảm xúc hoặc attention score;
3. **Tính đáng tin:** tín hiệu chỉ nên được phát khi mức độ tin cậy đủ cao.

3.2. Tổng quan kiến trúc SAFE-Alert

Hình 1 minh họa toàn bộ pipeline của SAFE-Alert, từ tầng chọn lọc tin tức, suy luận dựa trên yếu tố, hợp nhất đa phương thức với ngữ cảnh thị trường đa khung thời gian, cho đến tầng dự báo, giải thích và cảnh báo nhận thức độ tin cậy.

Để giải quyết bài toán trên, chúng tôi đề xuất kiến trúc **SAFE-Alert** (*Selective Attentive Factor-Explainable Alerting*), gồm bốn tầng chính:

1. **Selective News Encoder:** mã hóa tập tin tức và học cách chọn ra một tập bài viết quan trọng nhất cho từng tài sản và chân trời dự báo;
2. **Factor-grounded Reasoning:** ánh xạ các bài viết đã chọn sang các yếu tố tài chính có cấu trúc, đóng vai trò như tầng diễn giải trung gian;

3. **Multi-timescale Market Fusion:** hợp nhất thông tin từ tin tức đã chọn, các yếu tố tài chính và trạng thái thị trường đa khung thời gian để tạo ra dự báo;
4. **Confidence-aware Alerting:** ước lượng độ tin cậy của tín hiệu và quyết định có phát cảnh báo hay không.

Hình thức hóa, SAFE-Alert có thể được viết như sau:

$$\mathbf{Z}_{s,t,h}^{news} = \Phi_{sel}(\mathcal{N}_{s,t}, \mathcal{M}_{s,t}, h), \quad (2)$$

$$\mathbf{Z}_{s,t,h}^{fac} = \Phi_{fac}(\mathbf{Z}_{s,t,h}^{news}), \quad (3)$$

$$\mathbf{Z}_{s,t}^{mkt} = \Phi_{mkt}(\mathcal{M}_{s,t}), \quad (4)$$

$$\mathbf{Z}_{s,t,h}^{fus} = \Phi_{fus}(\mathbf{Z}_{s,t,h}^{news}, \mathbf{Z}_{s,t,h}^{fac}, \mathbf{Z}_{s,t}^{mkt}, h), \quad (5)$$

$$\left(\hat{y}_{s,t}^{(h)}, \hat{r}_{s,t}^{(h)}, \hat{c}_{s,t}^{(h)}\right) = \Phi_{pred}(\mathbf{Z}_{s,t,h}^{fus}), \quad (6)$$

$$\hat{\mathcal{E}}_{s,t}^{(h)} = \Phi_{exp}(\mathbf{Z}_{s,t,h}^{news}, \mathbf{Z}_{s,t,h}^{fac}, \hat{y}_{s,t}^{(h)}, \hat{c}_{s,t}^{(h)}). \quad (7)$$

Ở đây, Φ_{sel} là mô-đun chọn lọc tin tức, Φ_{fac} là mô-đun trích xuất yếu tố tài chính, Φ_{mkt} là mô-đun mã hóa ngữ cảnh thị trường, Φ_{fus} là mô-đun hợp nhất đa phương thức, Φ_{pred} là các đầu ra dự báo và độ tin cậy, còn Φ_{exp} là mô-đun sinh giải thích.

3.3. Mã hóa tin tức và chọn lọc bằng chứng

3.3.1. Mã hóa bài viết

Mỗi bài viết n_i được ánh xạ thành một biểu diễn vector:

$$\mathbf{e}_i = \Phi_{news}(x_i, m_i, h) \in \mathbb{R}^{d_n}, \quad (8)$$

trong đó Φ_{news} là bộ mã hóa tin tức, có thể được khởi tạo từ một mô hình ngôn ngữ miền tài chính hoặc từ encoder sentiment sẵn có của hệ thống. Việc đưa chân trời h vào đầu vào encoder là có chủ ý: cùng một bài viết có thể hữu ích cho dự báo 15 phút nhưng ít ý nghĩa hơn cho dự báo 24 giờ.

Để gắn kết bài viết với trạng thái thị trường hiện tại, trước tiên ta xây một vector truy vấn điều kiện hóa theo tài sản và horizon:

$$\mathbf{q}_{s,t,h} = \mathbf{W}_q [\bar{\mathbf{m}}_{s,t}; \mathbf{h}_{emb}] + \mathbf{b}_q, \quad (9)$$

trong đó $\bar{\mathbf{m}}_{s,t}$ là một biểu diễn tóm lược sơ bộ của ngữ cảnh thị trường, còn $\mathbf{h}_{emb}$ là embedding của horizon h .

3.3.2. Scoring và lựa chọn Top-K thích nghi

Với mỗi bài viết n_i , SAFE-Alert tính một điểm liên quan:

$$a_i = \mathbf{v}^\top \tanh(\mathbf{W}_e \mathbf{e}_i + \mathbf{W}_q \mathbf{q}_{s,t,h} + \mathbf{W}_m \mathbf{m}_i), \quad (10)$$

trong đó $\mathbf{m}_i$ là vector metadata của bài báo. Các điểm a_i được chuẩn hóa thành trọng số chọn lọc:

$$\alpha_i = \frac{\exp(a_i/\tau)}{\sum_{j=1}^{N_{s,t}} \exp(a_j/\tau)}, \quad (11)$$

với τ là nhiệt độ điều khiển độ sắc nét của phân phối.

Để xấp xỉ một lựa chọn Top-K nhưng vẫn khả vi khi huấn luyện, chúng tôi dùng một lớp chọn lọc mềm:

$$\tilde{\alpha}_i = \alpha_i \cdot \mathbb{I}(i \in \text{TopK}(\mathbf{a}, K_h)), \quad (12)$$

trong đó K_h có thể phụ thuộc vào horizon h . Trong triển khai, có thể thay thế chỉ báo rời rạc bằng một relaxation liên tục để gradient lan truyền ổn định hơn.

Biểu diễn tổng hợp của tập tin đã chọn được tính bởi:

$$\mathbf{z}_{s,t,h}^{news} = \sum_{i=1}^{N_{s,t}} \tilde{\alpha}_i \mathbf{e}_i. \quad (13)$$

Thiết kế này kế thừa tinh thần của các mô hình selective news selection gần đây [4], nhưng khác ở chỗ các trọng số chọn lọc không chỉ phục vụ dự báo mà còn trở thành một phần của *bằng chứng giải thích* và *chính sách cảnh báo*.

3.4. Biểu diễn yếu tố tài chính có cấu trúc

Một nhược điểm của nhiều hệ thống XAI tài chính là giải thích vẫn dừng ở mức sentiment score hoặc attention weight, vốn khó diễn giải ở cấp độ quyết định. Để khắc phục điều này, SAFE-Alert đưa vào một tầng *factor-grounded reasoning*. Ý tưởng ở đây là ánh xạ các bài viết đã chọn sang một tập yếu tố tài chính có ý nghĩa, ví dụ:

institutional inflow, ETF flow, regulatory easing, regulatory tightening, exchange risk, liquidity squeeze, whale accumulation, macro uncertainty, protocol upgrade, network outage.

Gọi $\mathcal{F} = \{f_1, \dots, f_C\}$ là ontology yếu tố với C classes. Với mỗi bài viết đã chọn, ta ước lượng phân phối yếu tố:

$$\mathbf{p}_i^{fac} = \text{softmax}(\mathbf{W}_{fac}\mathbf{e}_i + \mathbf{b}_{fac}) \in \mathbb{R}^C. \quad (14)$$

Biểu diễn yếu tố của toàn bộ tập bằng chứng được gộp có trọng số:

$$\mathbf{z}_{s,t,h}^{fac} = \sum_{i=1}^{N_{s,t}} \tilde{\alpha}_i \mathbf{U} \mathbf{p}_i^{fac}, \quad (15)$$

trong đó $\mathbf{U} \in \mathbb{R}^{d_f \times C}$ là ma trận embedding yếu tố.

Theo cách này, tầng yếu tố đóng vai trò như một *lớp tri thức trung gian* giữa văn bản và quyết định, đồng thời cho phép hệ thống xuất ra các giải thích có cấu trúc thay vì các câu mô tả mơ hồ. Mô-đun này được lấy cảm hứng từ xu hướng factor extraction dựa trên LLM trong dự báo tài chính [6], nhưng trong SAFE-Alert, nó còn được dùng để điều khiển cảnh báo và ràng buộc độ trung thực của giải thích.

3.5. Mã hóa ngữ cảnh thị trường đa khung thời gian

Thị trường được quan sát ở nhiều khung thời gian khác nhau. Với mỗi $\delta \in \Delta$, ta có tensor thị trường:

$$\mathbf{X}_{s,t}^{(\delta)} = [\mathbf{x}_{t-L_\delta+1}^{(\delta)}, \dots, \mathbf{x}_t^{(\delta)}] \in \mathbb{R}^{L_\delta \times d_\delta}, \quad (16)$$

trong đó mỗi $\mathbf{x}_u^{(\delta)}$ có thể bao gồm các đặc trưng như returns, volume, volatility, spread, technical indicators hoặc market microstructure features.

SAFE-Alert dùng một bộ mã hóa riêng cho từng khung thời gian:

$$\mathbf{u}_{s,t}^{(\delta)} = \Phi_{mkt}^{(\delta)}(\mathbf{X}_{s,t}^{(\delta)}) \in \mathbb{R}^{d_m}. \quad (17)$$

Sau đó, các biểu diễn theo timeframe được hợp nhất bằng attention:

$$\beta_\delta = \frac{\exp(\mathbf{w}_\delta^\top \tanh(\mathbf{W}_\delta \mathbf{u}_{s,t}^{(\delta)} + \mathbf{W}_h \mathbf{h}_{emb}))}{\sum_{\delta' \in \Delta} \exp(\mathbf{w}_{\delta'}^\top \tanh(\mathbf{W}_{\delta'} \mathbf{u}_{s,t}^{(\delta')} + \mathbf{W}_h \mathbf{h}_{emb}))}, \quad (18)$$

$$\mathbf{z}_{s,t,h}^{mkt} = \sum_{\delta \in \Delta} \beta_\delta \mathbf{u}_{s,t}^{(\delta)}. \quad (19)$$

Điều này cho phép mô hình học rằng các chân trời khác nhau cần chú ý đến các timeframe khác nhau; ví dụ, dự báo 15 phút có thể phụ thuộc mạnh vào khung 1m hoặc 5m, trong khi dự báo 24 giờ có thể dựa nhiều hơn vào khung 1h hoặc 4h.

3.6. Hợp nhất đa phương thức và đầu ra dự báo

SAFE-Alert hợp nhất ba nguồn biểu diễn:

- biểu diễn tin tức đã chọn $\mathbf{Z}_{s,t,h}^{news}$,
- biểu diễn yếu tố tài chính $\mathbf{Z}_{s,t,h}^{fac}$,
- biểu diễn thị trường đa khung thời gian $\mathbf{Z}_{s,t,h}^{mkt}$.

Một cách hợp nhất hiệu quả là dùng cross-attention hai tầng:

$$\tilde{\mathbf{Z}}_{s,t,h}^{news} = \text{CrossAttn}(\mathbf{Z}_{s,t,h}^{news}, \mathbf{Z}_{s,t,h}^{mkt}), \quad (20)$$

$$\tilde{\mathbf{Z}}_{s,t,h}^{fac} = \text{CrossAttn}(\mathbf{Z}_{s,t,h}^{fac}, \mathbf{Z}_{s,t,h}^{mkt}). \quad (21)$$

Biểu diễn hợp nhất cuối cùng được định nghĩa là:

$$\mathbf{Z}_{s,t,h}^{fus} = \text{MLP}([\tilde{\mathbf{Z}}_{s,t,h}^{news}; \tilde{\mathbf{Z}}_{s,t,h}^{fac}; \mathbf{Z}_{s,t,h}^{mkt}; \mathbf{h}_{emb}]). \quad (22)$$

Từ $\mathbf{Z}_{s,t,h}^{fus}$, mô hình sinh ra ba đầu ra:

$$\hat{\mathbf{p}}_{s,t}^{(h)} = \text{softmax}(\mathbf{W}_y \mathbf{Z}_{s,t,h}^{fus} + \mathbf{b}_y), \quad (23)$$

$$\hat{r}_{s,t}^{(h)} = \mathbf{W}_r \mathbf{Z}_{s,t,h}^{fus} + b_r, \quad (24)$$

$$\hat{c}_{s,t}^{(h)} = \sigma(\mathbf{W}_c \mathbf{Z}_{s,t,h}^{fus} + b_c), \quad (25)$$

trong đó $\hat{\mathbf{p}}_{s,t}^{(h)}$ là phân phối xác suất cho ba lớp hướng giá, $\hat{r}_{s,t}^{(h)}$ là suất sinh lợi kỳ vọng, và $\hat{c}_{s,t}^{(h)}$ là mức độ tin cậy.

3.7. Cơ chế cảnh báo nhận thức độ tin cậy

Khác với các hệ thống luôn phát tín hiệu sau mỗi lần suy luận, SAFE-Alert đưa ra một quyết định *alert* hoặc *abstain* dựa trên confidence. Với mỗi (s, t, h) , hệ thống phát cảnh báo nếu:

$$\mathbb{A}_{s,t}^{(h)} = \begin{cases} 1, & \text{nếu } \hat{c}_{s,t}^{(h)} \geq \tau_h \text{ và } \max \hat{\mathbf{p}}_{s,t}^{(h)} \geq \gamma_h, \\ 0, & \text{ngược lại,} \end{cases} \quad (26)$$

trong đó τ_h là ngưỡng tin cậy và γ_h là ngưỡng độ sắc của phân phối dự báo cho chân trời h .

Thiết kế hai ngưỡng này có hai mục đích. Thứ nhất, τ_h giúp kiểm soát các tình huống mà biểu diễn hợp nhất vẫn chứa nhiều bất định. Thứ hai, γ_h giúp tránh các trường hợp mô hình có confidence tổng quát cao nhưng phân phối dự báo giữa các lớp vẫn chưa đủ phân biệt. Về mặt vận hành, chính sách này cho phép hệ thống *biết khi nào nên im lặng*, một đặc tính đặc biệt quan trọng trong bối cảnh cảnh báo tài chính.

3.8. Đầu ra giải thích

Giải thích trong SAFE-Alert được tổ chức thành hai tầng.

3.8.1. Giải thích có cấu trúc

Hệ thống xuất ra:

- tập bài viết được chọn $\mathcal{S}_{s,t,h}^{news}$,
- top- P yếu tố tài chính $\mathcal{S}_{s,t,h}^{fac}$,
- direction dự báo, confidence và horizon.

Các tập này được xác định bởi:

$$\mathcal{S}_{s,t,h}^{news} = \{n_i \mid i \in \text{TopK}(\mathbf{a}, K_h)\}, \quad (27)$$

$$\mathcal{S}_{s,t,h}^{fac} = \text{TopP}\left(\sum_{i=1}^{N_{s,t}} \tilde{\alpha}_i \mathbf{p}_i^{fac}, P\right). \quad (28)$$

3.8.2. Giải thích ở mức ngôn ngữ

Trên cơ sở bằng chứng có cấu trúc, một module ngôn ngữ nhẹ hoặc một bộ template có thể sinh diễn giải:

$$\hat{g}_{s,t}^{(h)} = \Phi_{txt}\left(\mathcal{S}_{s,t,h}^{news}, \mathcal{S}_{s,t,h}^{fac}, \hat{y}_{s,t}^{(h)}, \hat{c}_{s,t}^{(h)}\right). \quad (29)$$

Điểm quan trọng là Φ_{txt} không được phép giải thích tự do trên toàn bộ tập tin đầu vào; nó chỉ được điều kiện hóa trên *bằng chứng đã chọn* và *các yếu tố đã trích xuất*. Nhờ vậy, diễn giải bằng ngôn ngữ được neo chặt vào quá trình suy luận, giảm nguy cơ tạo ra lời giải thích hợp lý về mặt câu chữ nhưng không faithful về mặt mô hình.

3.9. Hàm mục tiêu huấn luyện

SAFE-Alert được huấn luyện bằng một hàm mất mát đa mục tiêu:

$$\mathcal{L} = \lambda_1 \mathcal{L}_{dir} + \lambda_2 \mathcal{L}_{ret} + \lambda_3 \mathcal{L}_{fac} + \lambda_4 \mathcal{L}_{sel} + \lambda_5 \mathcal{L}_{cal} + \lambda_6 \mathcal{L}_{faith} + \lambda_7 \mathcal{L}_{risk}, \quad (30)$$

trong đó các thành phần được định nghĩa như sau.

3.9.1. Mất mát dự báo hướng giá

$$\mathcal{L}_{dir} = - \sum_{c \in \{-1, 0, +1\}} y_{s,t,c}^{(h)} \log \hat{p}_{s,t,c}^{(h)}. \quad (31)$$

3.9.2. Mất mát hồi quy suất sinh lợi

$$\mathcal{L}_{ret} = \text{SmoothL1} \left(\hat{r}_{s,t}^{(h)}, r_{s,t}^{(h)} \right). \quad (32)$$

3.9.3. Mất mát yếu tố tài chính

Nếu có factor labels thật hoặc pseudo-labels từ pipeline tri thức/LLM, ta dùng:

$$\mathcal{L}_{fac} = - \sum_{i=1}^{N_{s,t}} \sum_{c=1}^C \tilde{y}_{i,c}^{fac} \log p_{i,c}^{fac}. \quad (33)$$

3.9.4. Regularization cho chọn lọc tin tức

Để tránh selector phân tán quá rộng hoặc luôn chọn cùng một kiểu bằng chứng, ta dùng một regularizer:

$$\mathcal{L}_{sel} = \left(\sum_{i=1}^{N_{s,t}} \tilde{\alpha}_i - K_h \right)^2 + \eta \sum_{i=1}^{N_{s,t}} \tilde{\alpha}_i \log \tilde{\alpha}_i. \quad (34)$$

3.9.5. Mất mát hiệu chỉnh độ tin cậy

Để làm cho $\hat{c}_{s,t}^{(h)}$ phản ánh đúng chất lượng dự báo, chúng tôi dùng Brier-style calibration:

$$\mathcal{L}_{cal} = \left(\hat{c}_{s,t}^{(h)} - \mathbb{I}[\hat{y}_{s,t}^{(h)} = y_{s,t}^{(h)}] \right)^2. \quad (35)$$

3.9.6. Mất mát faithfulness

Giải thích được xem là faithful nếu việc loại bỏ các bài viết và yếu tố được chọn làm giảm đáng kể độ chắc chắn của dự báo. Gọi $\hat{p}^{full}$ là xác suất lớp dự báo khi dùng đầy đủ selected evidence, và $\hat{p}^{mask}$ là xác suất khi che các evidence được chọn. Khi đó:

$$\mathcal{L}_{faith} = \max \left(0, m - \left(\hat{p}_{s,t,h}^{full} - \hat{p}_{s,t,h}^{mask} \right) \right), \quad (36)$$

với $m > 0$ là margin. Thành phần này khuyến khích mô hình chỉ giải thích bằng các evidence thực sự quan trọng.

3.9.7. Mất mát selective risk

Để tránh mô hình phát quá nhiều cảnh báo rủi ro cao, ta dùng một surrogate selective risk:

$$\mathcal{L}_{risk} = \frac{\sum_{(s,t,h)} \hat{c}_{s,t}^{(h)} \ell_{s,t}^{(h)}}{\sum_{(s,t,h)} \hat{c}_{s,t}^{(h)} + \epsilon} + \mu \max \left(0, \kappa - \frac{1}{B} \sum_{(s,t,h)} \hat{c}_{s,t}^{(h)} \right), \quad (37)$$

trong đó $\ell_{s,t}^{(h)}$ là lỗi dự báo cơ sở, κ là coverage mục tiêu, và B là batch size.

3.10. Suy luận gần thời gian thực và tích hợp hệ thống

SAFE-Alert được thiết kế để phù hợp với kiến trúc microservices hướng sự kiện. Tại thời điểm suy luận t , pipeline được thực hiện theo thứ tự:

1. **Crawler Service** cung cấp tập $\mathcal{N}_{s,t}$ sau khi crawl, deduplicate và chuẩn hóa;
2. **Stream/Market Service** cung cấp tensor $\mathcal{M}_{s,t}$ từ dữ liệu giá đa khung thời gian;
3. **AI Service** thực hiện lần lượt selection $\rightarrow$ factor extraction $\rightarrow$ fusion $\rightarrow$ forecasting $\rightarrow$ confidence scoring;
4. **Core Service** lưu lại selected evidence, factors, forecasts và confidence để phục vụ truy vấn, audit và replay;
5. **Notification Service** chỉ phát tín hiệu nếu điều kiện trong Eq. (26) được thỏa mãn;
6. **Backtest Service** có thể dùng cùng pipeline để đánh giá utility downstream của policy alert.

Nhờ đó, SAFE-Alert không chỉ là một kiến trúc mô hình, mà còn là một khung *news-to-signal* có thể triển khai trực tiếp trong môi trường gần thời gian thực.

3.11. Thảo luận về novelty của SAFE-Alert

Điểm mới của SAFE-Alert không nằm ở việc phát minh một encoder hoàn toàn mới cho văn bản hay chuỗi thời gian, mà ở **sự hợp nhất có chủ đích** của bốn bài toán vốn thường được nghiên cứu rời rạc:

1. chọn lọc bằng chứng từ dòng tin dày đặc;
2. ánh xạ bằng chứng sang các yếu tố tài chính có cấu trúc;
3. dự báo đa phương thức theo nhiều chân trời thời gian;
4. và phát cảnh báo có nhận thức độ tin cậy.

Nói cách khác, SAFE-Alert chuyển trọng tâm từ *forecasting from all available news* sang *trustworthy signal generation from selected evidence*. Chính sự chuyển dịch này làm cho phương pháp phù hợp hơn với yêu cầu của các hệ thống hỗ trợ quyết định tài chính thực tế, nơi câu hỏi quan trọng không chỉ là “mô hình dự báo đúng bao nhiêu”, mà còn là “mô hình có biết dùng bằng chứng nào, giải thích bằng gì, và khi nào nên im lặng hay không”.

3.12. Ví dụ minh họa trực quan cho SAFE-Alert

Để giúp làm rõ cách SAFE-Alert hoạt động, chúng tôi trình bày một ví dụ minh họa đơn giản với dữ liệu giả lập cho tài sản BTC tại thời điểm t , với chân trời dự báo $h = 4h$. Ví dụ này không nhằm thay thế thực nghiệm đầy đủ, mà chỉ để minh họa trực quan cách các mô-đun trong Section 3 tương tác với nhau.

3.12.1. Đầu vào

Giả sử trong cửa sổ tin tức gần nhất, hệ thống thu được $N_{BTC,t} = 5$ bài viết liên quan đến BTC. Đồng thời, hệ thống cũng có dữ liệu thị trường đa khung thời gian từ các nền gần nhất. Bảng 1 và Bảng 2 trình bày dữ liệu đầu vào rút gọn.

Bảng 1: Ví dụ đầu vào tin tức cho BTC tại thời điểm t .

ID	Nội dung tóm tắt	Recency	Nguồn	Novelty
n_1	Quỹ lớn mua thêm BTC trị giá 250 triệu USD	10 phút	cao	0.90
n_2	ETF Bitcoin ghi nhận dòng tiền vào tăng mạnh	25 phút	cao	0.85
n_3	Sàn giao dịch nhỏ gặp lỗi rút tiền ngắn hạn	20 phút	trung bình	0.60
n_4	Bài phân tích chung: BTC có thể tiếp tục biến động	15 phút	trung bình	0.30
n_5	Một KOL đăng nhận định lạc quan về thị trường	12 phút	thấp	0.20

Trong ví dụ này, dữ liệu thị trường cho thấy BTC đang ở trạng thái tăng tương đối ổn định, với volume tăng dần từ khung nhỏ đến khung lớn. Điều này hàm ý rằng hệ thống có thể xem các tin tức liên quan đến *institutional inflow* hoặc *ETF inflow* là đặc biệt quan trọng cho dự báo 4 giờ tới.

Bảng 2: Ví dụ đầu vào thị trường đa khung thời gian cho BTC tại thời điểm t .

Khung thời gian	Return gần nhất	Volatility	Volume ratio
1m	+0.10%	0.8	1.10
5m	+0.35%	1.1	1.25
15m	+0.60%	1.3	1.40
1h	+1.10%	1.5	1.55
4h	+2.20%	1.8	1.70

3.12.2. Bước 1: Mã hóa và chọn lọc tin tức

Theo Eq. (10) và Eq. (11), SAFE-Alert tính điểm liên quan a_i cho từng bài viết. Giả sử mô hình thu được các điểm như sau:

$$[a_1, a_2, a_3, a_4, a_5] = [2.40, 2.10, 0.95, 0.40, 0.20]. \quad (38)$$

Sau khi chuẩn hóa bằng softmax, ta có:

$$[\alpha_1, \alpha_2, \alpha_3, \alpha_4, \alpha_5] = [0.39, 0.29, 0.13, 0.10, 0.09]. \quad (39)$$

Giả sử hệ thống dùng $K_h = 2$ cho horizon 4h, khi đó theo Eq. (12), hai bài được giữ lại là:

$$\mathcal{S}_{BTC,t,4h}^{news} = \{n_1, n_2\}. \quad (40)$$

Điều này có nghĩa là SAFE-Alert xem hai tin “quỹ lớn mua thêm BTC” và “ETF inflow tăng mạnh” là hai bằng chứng quan trọng nhất cho tín hiệu hiện tại, thay vì dùng toàn bộ 5 tin đầu vào.

3.12.3. Bước 2: Trích xuất yếu tố tài chính

Theo Eq. (14), mỗi bài viết đã chọn được ánh xạ sang phân phối yếu tố tài chính. Giả sử ontology yếu tố rút gọn gồm:

$$\mathcal{F} = \{\text{institutional inflow, ETF flow, exchange risk, noise commentary}\}.$$

Với hai bài đã chọn, mô hình thu được:

$$\mathbf{p}_1^{fac} = [0.82, 0.10, 0.03, 0.05], \quad (41)$$

$$\mathbf{p}_2^{fac} = [0.18, 0.73, 0.04, 0.05]. \quad (42)$$

Từ đó, theo Eq. (15), các yếu tố nổi bật nhất là:

$$\mathcal{S}_{BTC,t,4h}^{fac} = \{\text{institutional inflow, ETF flow}\}. \quad (43)$$

Ở mức trực giác, hệ thống không chỉ biết “tin tích cực”, mà còn biết *tại sao* tin tích cực: vì dòng tiền tổ chức tăng và dòng tiền ETF đang hỗ trợ đà giá.

3.12.4. Bước 3: Mã hóa thị trường đa khung thời gian

Theo Eq. (18) và Eq. (19), SAFE-Alert gán trọng số cho từng khung thời gian khi dự báo 4 giờ. Giả sử các trọng số attention thu được là:

$$[\beta_{1m}, \beta_{5m}, \beta_{15m}, \beta_{1h}, \beta_{4h}] = [0.05, 0.10, 0.20, 0.30, 0.35]. \quad (44)$$

Kết quả này hợp lý vì với horizon 4 giờ, các khung 1h và 4h được ưu tiên hơn so với 1m và 5m.

3.12.5. Bước 4: Hợp nhất đa phương thức và dự báo

Từ các biểu diễn tin tức đã chọn, yếu tố tài chính và trạng thái thị trường, SAFE-Alert xây dựng biểu diễn hợp nhất $\mathbf{Z}_{BTC,t,4h}^{fus}$ theo Eq. (22), rồi sinh đầu ra dự báo theo Eq. (23)–(25).

Giả sử mô hình tạo ra:

$$\hat{\mathbf{p}}_{BTC,t}^{(4h)} = [0.08, 0.18, 0.74], \quad (45)$$

$$\hat{r}_{BTC,t}^{(4h)} = +1.8\%, \quad (46)$$

$$\hat{c}_{BTC,t}^{(4h)} = 0.81. \quad (47)$$

Điều này tương ứng với:

- xác suất BTC tăng trong 4 giờ tới là 0.74,
- mức tăng kỳ vọng là khoảng +1.8%,
- độ tin cậy tổng thể của tín hiệu là 0.81.

3.12.6. Bước 5: Quyết định cảnh báo

Giả sử hệ thống dùng ngưỡng:

$$\tau_{4h} = 0.75, \quad \gamma_{4h} = 0.70.$$

Vì:

$$\hat{c}_{BTC,t}^{(4h)} = 0.81 > \tau_{4h} \quad \text{và} \quad \max \hat{\mathbf{p}}_{BTC,t}^{(4h)} = 0.74 > \gamma_{4h},$$

nên theo Eq. (26), hệ thống quyết định:

$$\mathbb{A}_{BTC,t}^{(4h)} = 1, \quad (48)$$

tức là **phát cảnh báo**.

Ngược lại, nếu cùng đầu vào nhưng $\hat{c}_{BTC,t}^{(4h)} = 0.58$, thì hệ thống sẽ chọn *abstain* thay vì gửi một tín hiệu kém chắc chắn.

3.12.7. Bước 6: Sinh giải thích

Theo Eq. (29), giải thích được sinh từ tập tin đã chọn và các yếu tố tài chính đã trích xuất. Một ví dụ đầu ra có thể là:

Tín hiệu: BTC có khả năng tăng trong 4 giờ tới.

Độ tin cậy: 0.81.

Bằng chứng chính: (i) quỹ lớn mua thêm BTC, (ii) dòng tiền ETF tăng mạnh.

Yếu tố chi phối: institutional inflow và ETF flow.

Giải thích: Mô hình nhận thấy tín hiệu tăng hiện tại được hỗ trợ đồng thời bởi dòng tiền tổ chức và bối cảnh thị trường đa khung thời gian đang tích cực, với volume tăng dần từ khung ngắn đến khung dài. Các tin còn lại được xem là ít quan trọng hơn hoặc có mức tác động lịch sử thấp.

3.12.8. Kiểm tra trực giác về faithfulness

Để minh họa ý tưởng trong Eq. (36), giả sử ta che hai bài viết được chọn n_1 và n_2 . Khi đó xác suất lớp *up* giảm từ:

$$\hat{p}_{BTC,t,4h}^{full} = 0.74 \quad \text{xuống} \quad \hat{p}_{BTC,t,4h}^{mask} = 0.41.$$

Mức giảm này cho thấy các bài được chọn thực sự là *bằng chứng quan trọng*, chứ không chỉ được đưa vào để làm cho lời giải thích nghe hợp lý. Nói cách khác, explanation của SAFE-Alert có cơ sở trực tiếp từ quá trình suy luận.

3.12.9. Tóm tắt ví dụ

Ví dụ trên cho thấy SAFE-Alert hoạt động theo logic sau:

1. nhận nhiều tin tức và ngữ cảnh thị trường đa khung thời gian;
2. chọn ra một tập tin nhỏ nhưng quan trọng nhất;
3. ánh xạ các tin này sang các yếu tố tài chính có nghĩa;
4. kết hợp các yếu tố đó với trạng thái thị trường để dự báo;
5. chỉ phát cảnh báo khi mức tin cậy đủ cao;
6. và sinh giải thích bám chặt vào đúng các bằng chứng đã chọn.

Nhờ đó, hệ thống không chỉ trả lời câu hỏi “*giá có thể tăng hay giảm?*”, mà còn trả lời được ba câu hỏi quan trọng hơn trong thực tế triển khai: “*vì sao?*”, “*dựa trên tin nào?*”, và “*có nên phát tín hiệu lúc này hay không?*”.

4. Thiết lập thực nghiệm

Mục tiêu của phần thực nghiệm là kiểm chứng bốn giả thuyết trung tâm của SAFE-Alert: (i) chọn lọc tin tức có giúp cải thiện chất lượng dự báo hay không, (ii) giải thích dựa trên yếu tố có trung thực và hữu ích hơn các lời giải thích hậu nghiệm hay không, (iii) cảnh báo nhận thức độ tin cậy có làm tăng chất lượng tín hiệu downstream hay không, và (iv) một khung thống nhất kết hợp selection, forecasting, explanation và alerting có tạo ra lợi ích tổng hợp về cả học máy lẫn utility tài chính hay không. Để đánh giá các giả thuyết này trong bối cảnh gần thời gian thực, chúng tôi xây dựng một benchmark nội bộ từ chính nền tảng microservices hiện có, đồng thời áp dụng một giao thức *pseudo-online* nghiêm ngặt nhằm tránh rò rỉ thông tin tương lai.

4.1. Nguồn dữ liệu và xây dựng benchmark từ hệ thống hiện có

4.1.1. Nguồn dữ liệu thô

Benchmark được xây dựng từ ba luồng dữ liệu chính do hệ thống hiện có sinh ra:

1. **Luồng tin tức tài chính:** được thu thập bởi *Crawler Service*, bao gồm nội dung bài viết, thời điểm công bố, thời điểm hệ thống ingest, nguồn tin, liên kết bài viết, thông tin deduplication và các metadata liên quan đến độ mới, độ dài và độ tin cậy nguồn.
2. **Luồng thị trường thời gian thực:** được cung cấp bởi *stream-ingester* và *stream-service*, bao gồm dữ liệu nền và các đặc trưng giao dịch theo nhiều khung thời gian cho từng tài sản.
3. **Luồng dự báo và nhật ký hệ thống:** được sinh bởi *AI Service*, *Notification Service*, *Core Service* và *Backtest Service*, bao gồm sentiment hiện có, AI insights, prediction logs, explanation logs, alert decisions và kết quả backtest.

Các nguồn dữ liệu này tạo thành một *event timeline* nhất quán, trong đó mỗi bài viết, trạng thái thị trường, dự báo và cảnh báo đều được gắn với timestamp rõ ràng. Đây là điều kiện then chốt để xây dựng benchmark *news-to-signal* ở chế độ gần thời gian thực.

4.1.2. Đơn vị phân tích

Đơn vị phân tích cơ bản của benchmark là một bộ tứ:

$$(s, t, h, \mathcal{N}_{s,t}), \quad (49)$$

trong đó:

- s là tài sản mục tiêu;
- t là thời điểm ra quyết định;
- $h \in \mathcal{H} = \{15m, 1h, 4h, 24h\}$ là chân trời dự báo;
- $\mathcal{N}_{s,t}$ là tập bài viết liên quan đến s trong cửa sổ tin tức trước thời điểm t .

Với mỗi đơn vị phân tích, hệ thống phải trả lời ba câu hỏi: *giá có đi lên hay đi xuống, mức độ chắc chắn của tín hiệu là bao nhiêu, và những bằng chứng nào giải thích cho quyết định đó*. Khung này cho phép đánh giá đồng thời dự báo, giải thích và alerting.

4.1.3. Lọc dữ liệu và chuẩn hóa

Trước khi tạo benchmark, dữ liệu được xử lý theo bốn bước:

1. **Deduplication**: các bài viết trùng lặp hoặc gần trùng lặp được gom cụm để tránh khuếch đại cùng một sự kiện.
2. **Entity-to-symbol linking**: chỉ giữ các bài viết có mức tin cậy đủ cao trong việc liên kết với tài sản mục tiêu.
3. **Temporal consistency**: sử dụng *timestamp ingest* thay vì chỉ *timestamp publication* để đảm bảo chỉ những bài thực sự đã đến hệ thống trước thời điểm t mới được dùng trong suy luận.
4. **Quality filtering**: loại bỏ các bài có nội dung quá ngắn, bài spam, hoặc bài không đạt ngưỡng tối thiểu về độ tin cậy nguồn.

Thiết kế này giúp benchmark phản ánh đúng môi trường vận hành thực tế hơn so với việc giả định rằng mọi bài báo đều ngay lập tức và hoàn toàn khả dụng tại thời điểm công bố.

4.1.4. Xây dựng nhãn dự báo

Với mỗi tài sản s và thời điểm quyết định t , chúng tôi xây dựng nhãn cho từng horizon h dựa trên suất sinh lợi tiến về phía trước:

$$r_{s,t}^{(h)} = \frac{P_{s,t+h}^{close} - P_{s,t}^{exec}}{P_{s,t}^{exec}}, \quad (50)$$

trong đó $P_{s,t}^{exec}$ là giá thực thi mô phỏng, được lấy là giá mở cửa của nền đầu tiên sau thời điểm ra quyết định để tránh look-ahead bias.

Từ $r_{s,t}^{(h)}$, nhãn phân lớp hướng giá được xác định theo:

$$y_{s,t}^{(h)} = \begin{cases} +1, & \text{nếu } r_{s,t}^{(h)} > \epsilon_h, \\ 0, & \text{nếu } |r_{s,t}^{(h)}| \leq \epsilon_h, \\ -1, & \text{nếu } r_{s,t}^{(h)} < -\epsilon_h, \end{cases} \quad (51)$$

trong đó ϵ_h là ngưỡng trung tính phụ thuộc horizon, dùng để tránh gán nhãn tăng/giảm cho các dao động nhiễu rất nhỏ.

Bên cạnh nhãn hướng giá, benchmark còn lưu:

- suất sinh lợi liên tục $r_{s,t}^{(h)}$ cho nhiệm vụ hồi quy,
- volatility tương lai trong khoảng $[t, t + h]$,
- trạng thái thị trường (*regime*) nếu cần cho các thí nghiệm phân tầng.

4.1.5. Tập bằng chứng và ontology yếu tố

Để phục vụ tầng giải thích trong SAFE-Alert, benchmark còn lưu thêm:

1. **selected evidence candidates**: tập bài viết ứng viên trong cửa sổ $[t - W_n, t]$;
2. **factor ontology**: tập yếu tố tài chính hữu hạn, được xây dựng từ tri thức miền và các mẫu tin lặp lại trong hệ thống, chẳng hạn: *institutional inflow*, *ETF flow*, *regulatory easing*, *exchange risk*, *liquidity squeeze*, *whale accumulation*, *macro tightening*.

Với ontology này, chúng tôi xây dựng một tập con được gán nhãn hoặc kiểm định bán thủ công để đánh giá chất lượng factor extraction và explanation faithfulness. Thiết kế này phù hợp với xu hướng factor-based explanation trong dự báo tài chính [6] và với các khuyến nghị gần đây về XAI tài chính có cấu trúc [5].

4.2. Giao thức pseudo-online

4.2.1. Động cơ

Các thí nghiệm tài chính dễ bị lạc quan giả tạo nếu dữ liệu được trộn ngẫu nhiên hoặc nếu mô hình được phép nhìn thấy những bài viết, trạng thái thị trường hay metadata chỉ xuất hiện sau thời điểm ra quyết định. Để tránh điều này, chúng tôi dùng một giao thức *pseudo-online*, trong đó toàn bộ pipeline được phát lại theo dòng thời gian thực, và tại mỗi thời điểm t , hệ thống chỉ được truy cập những thông tin thực sự khả dụng trước hoặc đúng lúc t .

4.2.2. Mốc quyết định và cửa sổ quan sát

Các quyết định được tạo ra tại các mốc đồng hồ cố định, ký hiệu là $\mathcal{T}_{dec}$, ví dụ theo nhịp 15 phút. Tại mỗi $t \in \mathcal{T}_{dec}$:

1. hệ thống lấy tập tin tức $\mathcal{N}_{s,t}$ trong cửa sổ $[t - W_n, t]$;
2. lấy tensor thị trường đa khung thời gian $\mathcal{M}_{s,t}$ trong cửa sổ quan sát $[t - W_m, t]$;
3. chạy SAFE-Alert để sinh dự báo, confidence, evidence và explanation;
4. áp dụng chính sách cảnh báo theo Eq. (26);
5. ghi nhận log dự báo trước khi thấy dữ liệu tương lai.

Thiết kế này bảo đảm rằng mọi quyết định trong benchmark đều có thể được xem như một bước suy luận gần thời gian thực.

4.2.3. Walk-forward evaluation

Toàn bộ dữ liệu được chia theo thời gian thành ba vùng:

- **train**: đoạn đầu của chuỗi thời gian,
- **validation**: đoạn giữa,
- **test**: đoạn cuối.

Để tăng độ chắc chắn cho đánh giá, chúng tôi áp dụng *walk-forward evaluation* theo cơ chế expanding window:

1. huấn luyện mô hình trên giai đoạn đầu;
2. chọn siêu tham số trên validation tiếp theo;
3. đánh giá trên test ngay sau đó;
4. trượt cửa sổ tiến về phía trước và lặp lại.

Ngoài ra, giữa các vùng thời gian chúng tôi áp dụng một khoảng *embargo* để giảm rò rỉ gián tiếp qua các sự kiện kéo dài hoặc các chuỗi tin liên tục liên quan đến cùng một biến cố lớn.

4.2.4. Mô phỏng thực thi và chi phí giao dịch

Để đánh giá utility downstream, mọi tín hiệu được giả định thực thi tại:

$$P_{s,t}^{exec} = P_{s, \text{next-open}(t)}, \quad (52)$$

thay vì dùng giá đóng tại chính thời điểm t . Thiết kế này giúp tránh look-ahead bias và phản ánh thực tế rằng tín hiệu cần một độ trễ nhỏ để được phát và thực thi.

Mỗi giao dịch trong backtest được điều chỉnh bởi:

- transaction cost cố định,
- slippage,
- optional spread penalty nếu dùng dữ liệu vi mô đầy đủ.

4.3. Các baseline so sánh

Để kiểm chứng từng thành phần của SAFE-Alert, chúng tôi chia baseline thành bốn nhóm.

4.3.1. Baseline dựa trên giá thuần túy

- **Market-Only**: chỉ dùng dữ liệu thị trường đa khung thời gian, không dùng tin tức;
- **Current Price Predictor**: mô hình dự báo giá hiện có trong nền tảng, dùng lại backbone đang vận hành nhưng không có selective explanation và alert gating.

Nhóm baseline này giúp đánh giá giá trị biên của văn bản trong môi trường giàu tín hiệu thị trường.

4.3.2. Baseline dùng toàn bộ tin tức

- **All-News Fusion**: gộp toàn bộ bài viết trong cửa sổ tin tức, không có news selection;
- **Sentiment+Market Fusion**: dùng sentiment score hiện có của nền tảng kết hợp với market features;
- **All-News + LLM Explanation**: dự báo từ toàn bộ tin, sau đó dùng LLM sinh diễn giải hậu nghiệm.

Các baseline này kiểm tra trực tiếp giả thuyết rằng việc dùng *mọi tin* là kém hiệu quả hơn dùng *selected evidence*.

4.3.3. Baseline lấy cảm hứng từ literature

- **NSM-style Selection**: phiên bản chọn lọc headline dựa trên cơ chế tương tự [4], nhưng không có factor-grounded alerting;
- **LLMFactor-style Forecasting**: sử dụng factor extraction kiểu [6], nhưng không có adaptive selection và confidence-aware alerting;

- **SEP-style Explainable Prediction:** dùng chiến lược sinh explanation theo tinh thần [7], nhưng không tích hợp evidence gating;
- **FININ-style Multimodal Model:** mô hình hóa news-market interactions theo tinh thần [2];
- **Interleaved Text–Time-Series Model:** baseline đa phương thức kiểu [3].

Nhóm này giúp đối chiếu SAFE-Alert với các xu hướng nghiên cứu mới nhất thay vì chỉ với các baseline đơn giản.

4.3.4. Baseline cho selective alerting

- **Always-Alert:** phát tín hiệu ở mọi thời điểm suy luận;
- **Raw-Probability Threshold:** phát tín hiệu khi xác suất lớp dự báo vượt ngưỡng;
- **Temperature-Scaled Threshold:** hiệu chỉnh hậu nghiệm rồi ngưỡng hóa;
- **Selective Forecasting Baseline:** phiên bản selective forecasting lấy cảm hứng từ [8], không có factor-grounded explanation.

Thiết kế này cho phép chúng tôi tách riêng hiệu quả của *confidence-aware alerting* khỏi hiệu quả của *forecasting model*.

4.4. Các tiêu chí đánh giá

Do SAFE-Alert là một khung nhiều mục tiêu, chúng tôi đánh giá theo bốn nhóm chỉ số.

4.4.1. Chỉ số dự báo

Đối với bài toán phân lớp hướng giá, chúng tôi báo cáo:

- Accuracy,
- Macro-F1,
- Matthews Correlation Coefficient (MCC),
- AUC trong trường hợp hai lớp hoặc one-vs-rest.

Đối với bài toán hồi quy suất sinh lợi, chúng tôi báo cáo:

- MAE,
- RMSE.

MCC được ưu tiên vì bài toán tài chính thường mất cân bằng lớp và Accuracy có thể gây ảo tưởng chất lượng.

4.4.2. *Chỉ số giải thích*

Để đánh giá explanation, chúng tôi dùng các chỉ số faithfulness và usefulness:

- **Sufficiency**: giữ lại selected evidence rồi đo mức giảm chất lượng dự báo;
- **Comprehensiveness**: che selected evidence rồi đo mức suy giảm confidence;
- **Deletion / Insertion**: đánh giá độ nhạy của đầu ra khi loại bỏ hoặc thêm các bằng chứng được chọn;
- **Factor Consistency**: mức ổn định của các yếu tố được trích xuất qua các lần suy luận tương tự;
- **Human Usefulness**: đánh giá trên một tập con bởi người có kiến thức miền.

Việc dùng faithfulness-oriented metrics phù hợp với các khuyến nghị gần đây trong XAI tài chính [5].

4.4.3. *Chỉ số calibration và selective forecasting*

Để đánh giá độ tin cậy và chính sách từ chối phát tín hiệu, chúng tôi báo cáo:

- Expected Calibration Error (ECE),
- Brier Score,
- Coverage,
- Selective Risk,
- Area under the Coverage–Risk Curve.

Nhóm chỉ số này giúp kiểm tra liệu confidence head có thực sự dự đoán tốt chất lượng tín hiệu hay không.

4.4.4. Chỉ số utility và chất lượng cảnh báo

Với tăng alerting và backtest, chúng tôi báo cáo:

- Hit Rate,
- Alert Precision,
- Alert Coverage,
- Profit & Loss,
- Sharpe Ratio,
- Sortino Ratio,
- Calmar Ratio,
- Maximum Drawdown.

Các chỉ số này đóng vai trò then chốt vì một mô hình có Accuracy cao nhưng phát nhiều tín hiệu sai hoặc tạo drawdown lớn vẫn khó có giá trị vận hành trong hệ thống thực.

4.5. Chi tiết cài đặt

4.5.1. Thiết lập huấn luyện

SAFE-Alert được triển khai bằng PyTorch. Bộ tối ưu được dùng là AdamW, với learning rate, weight decay, batch size và số epochs được chọn trên validation. Mô hình được huấn luyện với early stopping theo tiêu chí tổ hợp gồm Macro-F1, ECE và Sharpe trên validation.

Để ổn định huấn luyện, các trọng số trong hàm mất mát tổng hợp ở Eq. (30) được tuning theo chiến lược từng bước:

1. khởi tạo bằng cách ưu tiên $\mathcal{L}_{dir}$ và $\mathcal{L}_{ret}$;
2. bật $\mathcal{L}_{fac}$ và $\mathcal{L}_{faith}$ sau khi head dự báo hội tụ tương đối;
3. bật $\mathcal{L}_{cal}$ và $\mathcal{L}_{risk}$ ở giai đoạn fine-tuning để tránh destabilize đầu giai đoạn.

4.5.2. Khởi tạo encoder

Trong triển khai thực tế, bộ mã hóa tin tức Φ_{news} có thể được khởi tạo từ encoder miền tài chính sẵn có của hệ thống, trong khi market encoder Φ_{mkt} có thể tái sử dụng hoặc mở rộng backbone dự báo giá hiện hành. Cách làm này có hai lợi ích:

- giảm chi phí tích hợp vào nền tảng hiện có,
- bảo đảm baseline và mô hình đề xuất dùng cùng một hạ tầng đặc trưng cơ sở.

4.5.3. Factor extraction

Factor ontology được duy trì như một thành phần tri thức bán tĩnh. Tập pseudo-label cho factors được tạo bằng một pipeline gồm:

1. prompting trên selected news,
2. lọc theo consistency qua nhiều lần gọi,
3. kiểm tra thủ công trên một tập nhỏ.

Chiến lược này cân bằng giữa chi phí gán nhãn và chất lượng tri thức, đồng thời phù hợp với khuyến nghị trong các nghiên cứu gần đây về LLM cho tài chính [6, 11].

4.5.4. Suy luận gần thời gian thực

Trong môi trường chạy gần thời gian thực, chúng tôi cache:

- article embeddings,
- market tensors gần nhất,
- factor prompts và factor outputs đã chuẩn hóa.

Nhờ đó, mỗi chu kỳ suy luận chỉ cần cập nhật phần dữ liệu mới, thay vì tính lại toàn bộ pipeline từ đầu. Đây là điều kiện cần để SAFE-Alert phù hợp với kiến trúc microservices hướng sự kiện.

4.6. Phân tích theo nhóm thí nghiệm

Để trả lời đầy đủ các research questions, chúng tôi tổ chức thí nghiệm thành bốn nhóm:

1. **Forecasting study**: so sánh SAFE-Alert với các baseline về Accuracy, Macro-F1, MCC, RMSE và utility trading.

2. **Selection study:** kiểm tra hiệu quả của selective news selection so với all-news và heuristic selection.
3. **Explanation study:** đánh giá factor-grounded explanation bằng các chỉ số faithfulness và usefulness.
4. **Alerting study:** đánh giá calibration, selective risk, alert precision và utility của các chính sách alert khác nhau.

Thiết kế này bảo đảm rằng đóng góp của SAFE-Alert được phân tích không chỉ ở mức *mô hình tốt hơn*, mà còn ở mức *hệ thống hỗ trợ quyết định đáng tin hơn*.

4.7. Tóm tắt

Tóm lại, thiết lập thực nghiệm của chúng tôi được xây dựng xoay quanh một benchmark nội bộ có tính *event-driven*, *pseudo-online* và *utility-aware*, được tạo trực tiếp từ nền tảng microservices hiện có. Bằng cách đánh giá đồng thời chất lượng dự báo, độ trung thực của giải thích, hiệu chỉnh độ tin cậy và giá trị cảnh báo trong backtest, chúng tôi hướng tới một cách kiểm chứng nghiêm ngặt hơn cho các hệ thống *news-to-signal* trong tài chính thời gian thực. Phần tiếp theo sẽ trình bày kết quả định lượng và phân tích định tính của SAFE-Alert dưới các góc nhìn này.

5. Kết quả và thảo luận

Phần này trình bày kết quả định lượng và định tính của SAFE-Alert dưới bốn góc nhìn: (i) hiệu năng dự báo tổng thể, (ii) tác động của từng thành phần thông qua ablation study, (iii) phân tích case study về explanation và cơ chế alerting, và (iv) thảo luận ở góc nhìn hệ thống hỗ trợ quyết định theo phong cách ESWA. Do SAFE-Alert được thiết kế như một khung *news-to-signal* thay vì chỉ là một mô hình phân lớp/hồi quy thuần túy, chúng tôi không giới hạn việc đánh giá ở Accuracy hay RMSE, mà đồng thời xem xét explanation faithfulness, calibration, chất lượng cảnh báo và utility trong backtest.

5.1. Kết quả chính

5.1.1. Hiệu năng dự báo

Bảng 3 so sánh SAFE-Alert với các baseline chính trên tập kiểm tra pseudo-online. Các baseline được chia thành ba nhóm: (i) mô hình chỉ dùng thị trường, (ii) mô hình dùng toàn bộ tin tức, và (iii) các mô hình đại diện cho các hướng nghiên cứu gần đây về selective news, factor-based reasoning và multimodal forecasting.

Bảng 3: Kết quả chính trên bài toán dự báo hướng giá và hồi quy suất sinh lợi. Giá trị tốt nhất được in đậm, giá trị tốt nhì được gạch chân.

Mô hình	Accuracy	Macro-F1	MCC	RMSE ↓	ECE ↓	Coverage
Market-Only	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	1.00
Current Price Predictor	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	1.00
All-News Fusion	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	1.00
Sentiment + Market Fusion	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	1.00
NSM-style Selection	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
LLMFactor-style Forecasting	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	1.00
SEP-style Explainable Prediction	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	1.00
FININ-style Multimodal Model	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	1.00
Interleaved Text–Time-Series Model	<u>xx.xx</u>	<u>xx.xx</u>	<u>xx.xx</u>	<u>xx.xx</u>	xx.xx	1.00
SAFE-Alert	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx

Từ Bảng 3, có thể kiểm tra ba xu hướng quan trọng. Thứ nhất, nếu SAFE-Alert vượt các baseline *Market-Only* và *Current Price Predictor*, điều đó cho thấy tin tức vẫn mang lại giá trị biên đáng kể ngay cả khi hệ thống đã có trạng thái thị trường đa khung thời gian khá giàu thông tin. Thứ hai, nếu SAFE-Alert vượt các baseline *All-News Fusion* và *Sentiment + Market Fusion*, điều đó xác nhận rằng *không phải càng nhiều tin càng tốt*; ngược lại, bằng chứng được chọn lọc có thể mang tín hiệu đậm đặc hơn và giảm nhiễu hiệu quả hơn. Thứ ba, nếu SAFE-Alert đồng thời đạt ECE thấp hơn trong khi vẫn giữ được Accuracy/Macro-F1 cao, điều đó cho thấy lợi ích của cách tiếp cận *confidence-aware* trong một hệ thống tài chính có tính triển khai.

5.1.2. Hiệu năng cảnh báo và utility tài chính

Bảng 4 trình bày kết quả ở góc nhìn downstream: chất lượng cảnh báo và utility trong backtest. Đây là phần đặc biệt quan trọng vì một mô hình forecasting tốt về mặt học máy nhưng tạo ra cảnh báo nhiễu hoặc drawdown lớn vẫn khó có giá trị vận hành thực tế.

Bảng 4: Kết quả chất lượng cảnh báo và utility downstream.

Mô hình / Chính sách	Alert Precision	Hit Rate	Sharpe	Sortino	Calmar	Max Drawdown ↓	PnL
Always-Alert (Current Model)	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
Raw-Probability Threshold	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
Temperature-Scaled Threshold	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
Selective Forecasting Baseline	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
SAFE-Alert	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx

Nếu SAFE-Alert cải thiện rõ *Alert Precision* và *Sharpe* so với *Always-Alert*, thì đây là bằng chứng trực tiếp rằng cơ chế *abstain when uncertain* không chỉ cải thiện reliability mà còn tạo ra lợi ích thực tế về mặt quyết định. Đặc biệt, một mức

Max Drawdown thấp hơn sẽ là selling point rất mạnh cho ESWA, bởi nó cho thấy hệ thống không chỉ “dự báo tốt hơn” mà còn “hành xử có trách nhiệm hơn”.

5.2. Phân tích ablation

Để tách riêng tác động của từng thành phần trong SAFE-Alert, chúng tôi thực hiện ablation study trên các mô-đun chính: *selective news selection*, *factor-grounded explanation*, *multi-timescale market fusion*, *confidence-aware alerting*, và *faithfulness regularization*. Bảng 5 trình bày kết quả.

Bảng 5: Ablation study cho SAFE-Alert. Ký hiệu “w/o” chỉ phiên bản loại bỏ thành phần tương ứng.

Biến thể	Accuracy	Macro-F1	MCC	ECE ↓	Alert Precision	Sharpe	Faithfulness	Coverage
SAFE-Alert đầy đủ	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
w/o Selective News	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	1.00
w/o Factor Module	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
w/o Market Context	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
w/o Confidence Head	xx.xx	xx.xx	xx.xx	—	xx.xx	xx.xx	xx.xx	1.00
w/o Faithfulness Loss	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx
w/o Horizon Conditioning	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx	xx.xx

5.2.1. Tác động của selective news selection

Nếu biến thể *w/o Selective News* suy giảm rõ về Accuracy/Macro-F1/MCC, điều này xác nhận giả thuyết rằng selection không phải là một bước tiền xử lý tùy chọn mà là một thành phần lõi của bài toán. Sự suy giảm này đặc biệt có ý nghĩa nếu đi kèm với ECE xấu hơn và Alert Precision thấp hơn, vì nó cho thấy rằng việc đưa quá nhiều tin không chỉ làm kém dự báo mà còn làm mô hình kém tự tin một cách có tổ chức.

5.2.2. Tác động của factor-grounded explanation

Nếu *w/o Factor Module* không làm giảm mạnh Accuracy nhưng làm giảm đáng kể *Faithfulness* và *Alert Precision*, điều này có thể được diễn giải như sau: tăng factor không chỉ phục vụ “trang trí explanation”, mà còn đóng vai trò như một lớp trừu tượng hóa tri thức giúp mô hình học được cơ chế tín hiệu bền hơn. Đây là một selling point quan trọng, vì nó cho thấy factor-based explanation tạo ra giá trị cả về interpretability lẫn downstream decision quality.

5.2.3. Tác động của confidence-aware alerting

Biến thể *w/o Confidence Head* là một ablation rất quan trọng. Nếu Accuracy gần như không đổi nhưng Sharpe, Alert Precision và Max Drawdown xấu đi rõ rệt, điều đó chứng minh rằng *confidence-aware alerting* là một contribution độc lập

chứ không chỉ là một hậu xử lý đơn giản trên xác suất dự báo. Đây là điểm mà các reviewer ESWA thường đánh giá cao, vì nó cho thấy chuyển dịch từ *forecasting model* sang *decision-support system*.

5.2.4. Tác động của *faithfulness regularization*

Nếu *w/o Faithfulness Loss* tạo ra explanation nghe hợp lý nhưng có Deletion/Insertion score xấu hơn hoặc độ giảm confidence nhỏ hơn khi bỏ selected evidence, thì kết quả này cho thấy *faithfulness* không tự nhiên xuất hiện chỉ vì mô hình có một explanation head. Thay vào đó, nó cần được ép buộc trong huấn luyện như một mục tiêu riêng.

5.3. Phân tích case study về explanation

Để minh họa rõ hơn cách SAFE-Alert hoạt động trong môi trường gần thời gian thực, chúng tôi trình bày một case study điển hình cho BTC với horizon 4 giờ. Bảng 6 so sánh đầu ra của *All-News Fusion*, *SEP-style Explainable Prediction*, và *SAFE-Alert* trên cùng một cửa sổ dữ liệu.

Bảng 6: Ví dụ case study định tính cho một tín hiệu BTC ở horizon 4h.

Mô hình	Bảng chứng sử dụng	Giải thích	Direction	Confidence	Quyết định cảnh báo
All-News Fusion	8 bài trong 30 phút gần nhất	“Tin tức tích cực hỗ trợ xu hướng tăng”	UP	0.xx	Alert
SEP-style	8 bài, explanation sinh bởi LLM	“Dòng tiền thị trường và tâm lý tích cực đang hỗ trợ BTC”	UP	0.xx	Alert
SAFE-Alert	2 bài được chọn: ETF inflow, quỹ lớn mua BTC; factors: institutional inflow, ETF flow	“Tín hiệu tăng được hỗ trợ bởi dòng tiền tổ chức và dòng tiền ETF; các tin còn lại bị loại do tác động thấp hoặc trùng lặp.”	UP	0.xx	Alert / Abstain

5.3.1. Khả năng chọn lọc bằng chứng

Trong case study này, điểm khác biệt cốt lõi của SAFE-Alert là không sử dụng toàn bộ tập tin tức đầu vào. Thay vào đó, mô hình chỉ giữ lại hai bài có relevance score cao nhất và loại bỏ các bài nhiễu như nhận định chung chung hoặc bình luận xã hội ít giá trị dự báo. Nếu sau khi che hai bài viết được chọn, xác suất lớp *UP* giảm mạnh từ $\hat{p}^{full}$ xuống $\hat{p}^{mask}$, điều đó cho thấy explanation được neo chặt vào bằng chứng thật sự quan trọng, thay vì chỉ là câu mô tả có vẻ hợp lý.

5.3.2. Giải thích ở mức yếu tố

Một điểm mạnh của SAFE-Alert là chuyển explanation từ mức *headline-level* hoặc *sentiment-level* sang mức *factor-level*. Trong ví dụ trên, thay vì nói mơ hồ rằng “tin tích cực đang hỗ trợ thị trường”, SAFE-Alert chỉ ra rõ các yếu tố như *institutional inflow* và *ETF flow*. Ở góc nhìn hệ thống, điều này có hai lợi ích:

1. explanation trở nên có ý nghĩa tài chính hơn với người dùng,
2. tầng factor có thể được tái sử dụng như một lớp tri thức trung gian cho phân tích hoặc auditing sau này.

5.3.3. Phân biệt dự báo và quyết định phát cảnh báo

Case study cũng cho thấy sự khác biệt giữa *predicting* và *alerting*. Hai mô hình có thể cùng dự báo “UP”, nhưng nếu SAFE-Alert cho confidence thấp hơn ngưỡng τ_h , hệ thống sẽ chọn *abstain*. Đây là hành vi có giá trị thực tế cao, bởi trong các hệ thống cảnh báo tài chính, việc biết *khi nào không nên phát tín hiệu* thường quan trọng không kém việc dự báo đúng.

5.4. Thảo luận theo phong cách ESWA

5.4.1. SAFE-Alert có mới ở điểm nào?

Một phản biện hợp lý có thể là: từng thành phần trong SAFE-Alert đều đã có nghiên cứu gần đây, vậy novelty nằm ở đâu? Chúng tôi cho rằng novelty không nằm ở một encoder riêng lẻ, mà ở **sự hợp nhất có chủ đích** của bốn lớp vốn thường bị nghiên cứu tách rời:

- chọn lọc tin tức thích nghi,
- biểu diễn explanation ở mức yếu tố,
- hợp nhất đa phương thức với market context đa khung thời gian,
- và cảnh báo nhận thức độ tin cậy.

Điểm khác biệt quan trọng là SAFE-Alert không xem explanation như một phần “gắn thêm” sau dự báo. Thay vào đó, selection, factor extraction, confidence estimation và alerting được thiết kế đồng thời như các thành phần của một *decision-support loop*. Chính sự chuyển từ *news-to-prediction* sang *news-to-signal* làm cho đóng góp của bài mang tính hệ thống hơn, phù hợp với định hướng của ESWA.

5.4.2. Điểm mạnh của phương pháp

Kết quả nếu xác nhận các xu hướng ở trên sẽ cho thấy SAFE-Alert có bốn điểm mạnh rõ ràng.

(1) *Giảm information overload..* Selection giúp mô hình tập trung vào phần bằng chứng giàu tin hiệu nhất, từ đó cải thiện forecast quality và giảm nhiễu.

(2) *Tăng tính giải thích ở mức nghiệp vụ..* Factor-grounded explanations giúp biến đầu ra từ “mô hình nghĩ rằng giá sẽ tăng” thành “giá có khả năng tăng vì ETF inflow và institutional accumulation”, tức là gần hơn với ngôn ngữ mà các nhà phân tích hoặc người dùng hiểu được.

(3) *Tăng tính đáng tin khi triển khai..* Confidence-aware alerting giúp hệ thống tránh việc luôn phát tín hiệu. Trong môi trường tài chính thực, đây là điểm mạnh đặc biệt quan trọng vì nó làm giảm alert fatigue và giảm khả năng over-trading.

(4) *Phù hợp với hệ thống hiện có..* SAFE-Alert có thể được cắm trực tiếp vào nền tảng microservices hiện hành: *crawler-service* cung cấp raw evidence, *ai-service* đảm nhận selection/factor/prediction, *core-service* lưu evidence và explanation logs, *notification-service* triển khai alert policy, còn *backtest-service* đánh giá utility downstream. Điều này làm cho contribution của bài không chỉ mạnh về mô hình mà còn mạnh về khả năng triển khai.

5.4.3. Giới hạn của nghiên cứu

Dù có các điểm mạnh trên, SAFE-Alert vẫn có một số hạn chế cần được nhìn nhận thẳng thắn.

(1) *Phụ thuộc vào chất lượng linking giữa tin tức và tài sản..* Nếu bước entity-to-symbol linking sai hoặc quá lỏng, selector có thể học trên một tập bằng chứng nhiễu ngay từ đầu.

(2) *Factor ontology chưa hoàn toàn đóng..* Dù factor taxonomy giúp explanation rõ ràng hơn, thị trường tài chính luôn xuất hiện các yếu tố mới hoặc các biến thể ngữ nghĩa khó gom chuẩn. Điều này khiến factor extraction có thể cần tái huấn luyện hoặc mở rộng ontology định kỳ.

(3) *Calibration trong tài chính vẫn khó..* Ngay cả khi ECE được cải thiện, confidence trong môi trường thị trường biến động mạnh vẫn có thể bị lệch khi regime thay đổi nhanh. Đây là hạn chế chung của các hệ thống forecasting triển khai thật.

(4) *Utility phụ thuộc vào giả định backtest..* Các chỉ số như Sharpe, Sortino và MDD chịu ảnh hưởng bởi cách mô phỏng thực thi, transaction cost, slippage và policy giao dịch. Vì vậy, utility downstream cần được diễn giải cùng với bối cảnh chiến lược cụ thể, không nên tách rời.

5.4.4. Hàm ý cho hệ thống hỗ trợ quyết định tài chính

Ở góc nhìn ESWA, điểm đáng giá nhất của SAFE-Alert không phải là việc nó đạt thêm vài điểm phần trăm Accuracy, mà là việc nó minh họa một nguyên lý thiết kế quan trọng cho các hệ thống tài chính thông minh: **một hệ thống hỗ trợ quyết định nên biết chọn bằng chứng, biết diễn giải tín hiệu, và biết khi nào nên im lặng**. Đây là một chuyển dịch quan trọng so với các mô hình forecasting truyền thống, vốn thường tối ưu một objective duy nhất rồi đẩy toàn bộ gánh nặng giải thích và quản trị rủi ro xuống tầng người dùng cuối.

5.4.5. Hướng phát triển tiếp theo

Các kết quả trong bài này mở ra một số hướng mở rộng tự nhiên:

- mở rộng từ factor taxonomy tĩnh sang memory-based factor reasoning,
- bổ sung target-based financial sentiment ở mức thực thể,
- kết hợp conformal prediction hoặc uncertainty sets để tăng độ chặt của alert policy,
- và đánh giá SAFE-Alert trên các tài sản khác ngoài crypto hoặc trên các benchmark công khai đa thị trường.

5.5. Tóm tắt

Tóm lại, nếu các kết quả thực nghiệm đi theo xu hướng kỳ vọng, SAFE-Alert sẽ cho thấy ba thông điệp chính. Thứ nhất, *chọn đúng tin quan trọng* hiệu quả hơn *dùng mọi tin*. Thứ hai, *giải thích dựa trên yếu tố* vừa dễ hiểu hơn vừa faithful hơn so với explanation hậu nghiệm thông thường. Thứ ba, *cảnh báo nhận thức độ tin cậy* là một thành phần trung tâm để chuyển một mô hình dự báo thành một hệ thống hỗ trợ quyết định đáng tin. Các kết quả này tạo nên cơ sở cho kết luận rằng SAFE-Alert là một bước tiến hợp lý từ *forecasting model* sang *explainable and responsible financial decision-support system*.

Tài liệu

- [1] K. Du, F. Xing, R. Mao, E. Cambria, Financial sentiment analysis: Techniques and applications, ACM Computing Surveys 56 (9) (2024) 1–42. doi:10.1145/3649451.
URL <https://doi.org/10.1145/3649451>

- [2] M. Wang, S. B. Cohen, T. Ma, Modeling news interactions and influence for financial market prediction, in: Findings of the Association for Computational Linguistics: EMNLP 2024, Association for Computational Linguistics, Miami, Florida, USA, 2024, pp. 3302–3314. doi:10.18653/v1/2024.findings-emnlp.189.
URL <https://aclanthology.org/2024.findings-emnlp.189/>
- [3] R. Koval, N. Andrews, X. Yan, Multimodal language models for financial forecasting from interleaved sequences of text and time series, in: Proceedings of the 14th International Joint Conference on Natural Language Processing and the 4th Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics, The Asian Federation of Natural Language Processing and The Association for Computational Linguistics, Mumbai, India, 2025, pp. 987–1001. doi:10.18653/v1/2025.ijcnlp-long.54.
URL <https://aclanthology.org/2025.ijcnlp-long.54/>
- [4] J. Jang, Selective news selection model for explainable stock prediction via cross-attention integration, Finance Research Letters 85 (Part D) (2025) 108146. doi:10.1016/j.frl.2025.108146.
URL <https://doi.org/10.1016/j.frl.2025.108146>
- [5] W. J. Yeo, W. Van Der Heever, R. Mao, E. Cambria, R. Satapathy, G. Mengaldo, A comprehensive review on financial explainable ai, Artificial Intelligence Review 58 (2025) 189. doi:10.1007/s10462-024-11077-7.
URL <https://doi.org/10.1007/s10462-024-11077-7>
- [6] M. Wang, K. Izumi, H. Sakaji, Llmfactor: Extracting profitable factors through prompts for explainable stock movement prediction, in: Findings of the Association for Computational Linguistics: ACL 2024, Association for Computational Linguistics, Bangkok, Thailand, 2024, pp. 3120–3131. doi:10.18653/v1/2024.findings-acl.185.
URL <https://aclanthology.org/2024.findings-acl.185/>
- [7] K. J. L. Koa, Y. Ma, R. Ng, T.-S. Chua, Learning to generate explainable stock predictions using self-reflective large language models, in: Proceedings of the ACM Web Conference 2024, ACM, 2024, pp. 4304–4315. doi:10.1145/3589334.3645611.
URL <https://doi.org/10.1145/3589334.3645611>

- [8] J. Brusokas, S. Tirupathi, D. Zhang, T. B. Pedersen, The time-energy model: Selective time-series forecasting using energy-based models, Transactions on Machine Learning Research.
URL <https://openreview.net/forum?id=iHYCdTA0qF>
- [9] I. Muhammad, M. Rospocher, T. Knez, S. Žitnik, Benchmarking large language models for target-based financial sentiment analysis, in: Proceedings of the Eleventh Italian Conference on Computational Linguistics (CLiC-it 2025), Cagliari, Italy, 2025.
URL <https://aclanthology.org/2025.clicit-1.74/>
- [10] R. Kumar, C. Nolbaria, Bridging the data gap in financial sentiment: Llm-driven augmentation, in: Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 4: Student Research Workshop), Association for Computational Linguistics, Vienna, Austria, 2025, pp. 1246–1254. doi:10.18653/v1/2025.acl-srw.98.
URL <https://aclanthology.org/2025.acl-srw.98/>
- [11] F. Pallucchini, X. Zhang, R. Mao, E. Cambria, Self-explanatory and retrieval-augmented llms for financial sentiment analysis, in: Proceedings of the 40th ACM/SIGAPP Symposium on Applied Computing, ACM, Catania, Italy, 2025, pp. 131–137. doi:10.1145/3672608.3707894.
URL <https://doi.org/10.1145/3672608.3707894>